

特征几何用于数据池预筛选：效用、稳定性与局限

Anonymous authors

Paper under double-blind review

ABSTRACT

为目标任务选择源数据池，需要先判断哪些组合值得训练和验证。冻结表示允许在监督评价之前比较候选，但几何多样性本身并不说明所覆盖的方向是否与目标有关。本文研究两阶段方案，先用无标签特征构建短名单，再通过带标签的验证数据作最终选择。我们从有效秩出发，将归一化特征奇异值的熵取指数，考察合并特征的变化如何分布在不同方向上；随后比较由共享贝叶斯线性模型引出的目标加权 A-optimal 设计、二阶矩匹配和目标无关多样性准则。在 PACS 和 Office-Home 上，直接选择的收益较小，即使已评价的最佳组合相对基线也只有有限改善。在固定样本成本的 DomainNet 实验中，保留约一半组合，平均可召回测试 Brier 前十名中的 98.3%。探索性实验改变投影种子和分类器读出后，仍获得较高平均召回，包括候选损失差异更明显的情形。二阶矩匹配与 A-optimal 筛选具有竞争力。这些发现支持利用目标感知特征几何，缩小需要接受监督评价的源组合范围。

1 引言

将预测器用于一个目标域时，研究者往往有多个源数据池可供选择。这些数据池的采集条件、图像风格或样本覆盖范围可能不同。源组合是否有用取决于预期预测任务，因此通常需要先训练模型，再在目标验证数据上评价。即使单个模型很小，对所有组合重复这一过程也可能成本较高。实际需要解决的问题是：哪些组合值得进入监督评价？

预训练编码器提供了检查这些选择的共同空间。编码器将图像映射为特征向量；固定其参数后，同一批已提取特征可以在不同源组合和分类器拟合之间复用。CLIP、DINOv2 等视觉表示使这种设置具有现实基础 (Radford et al., 2021; Oquab et al., 2024)。将特征向量按行堆叠成矩阵后，无需拟合分类器就能测量其性质：样本数反映数据数量，奇异值描述不同特征方向得到多强的表示。这些测量可以为原本每次比较都需要标签的搜索提供初步依据。

有效秩是概括这种方向结构的一种方式。普通矩阵秩只统计非零奇异值，因此可能为方向分布均衡的表示和少数方向主导的表示赋予相同秩。有效秩则将奇异值归一化，计算其熵，再取指数 (Roy & Vetterli, 2007)。它描述了多少个等权方向能够产生相同的谱熵。RankMe 利用这一思路，在没有下游标签的情况下评价自监督表示 (Garrido et al., 2023)。对于源数据池选择，相应的直觉是：覆盖更多方向的组合，可能为学习提供更丰富的特征。

从表示评价转向数据池选择，还需要回答两个问题。首先，不同数据池的方向如何组合？两个数据池各自都可能具有较宽的谱，却覆盖特征空间中大致相同的部分；另一对数据池则可能互补。其次，合并后的哪些方向对目标重要？一个组合的有效秩较高，可能是因为它包含预测时很少遇到的变化。例如，若目标仅占据特征空间的一个较窄部分，增加该部分之外的变化，可能提高多样性评分，却没有改善目标覆盖。合并谱描述的是源变化，而预测还取决于目标分布以及特征与标签之间的关系。

这些问题提示我们，可以用几何保留备选方案，而不要求它直接决定最终模型。预筛选保留若干特征看起来与目标相关的组合，再由带标签的验证数据消除剩余不确定性。目标因此变为：在较小的评价预算内保留有用候选。这不同于为了几何分数本身而将其最大化。即使无法从特征准确预测候选的先后顺序，有用的短名单仍应包含目标表现较好的组合。

本文通过两阶段数据池预筛选协议研究这一方案。第一阶段使用无标签源特征和目标特征排列组合，第二阶段用源标签训练，并通过独立目标验证数据从短名单中选择。目标加权 A-optimal 设计偏好能够降低目标常见方向上不确定性的源组合，共享贝叶斯线性模型明确给出了这一联系。二阶矩匹配提出一个更简单的问题：源数据的平均方向能量与目标有多接近？将二者与合并有效秩及其他目标无关准则比较，可以区分目标信息的作用与具体评分函数的作用。

实验同时评价保留的候选与验证阶段的最终选择。在 PACS 和 Office-Home 上，直接选择的收益较小；穷举评价也发现，在这些候选族内，相对基线的改善空间有限。固定样本成本的 DomainNet 研究则表明，目标感知筛选可以在缩短监督评价名单的同时保留大部分有希望的组合。新增投影种子和分类器读出仍获得较高平均召回，二阶矩匹配与 A-optimal 筛选保持竞争力。结合有效秩的构造及目标加权风险的假设，本文说明几何能够为数据池预筛选提供什么，以及哪些决定仍需要任务证据。

2 相关工作

2.1 表示几何与多样性

RankMe 利用有效秩在无需下游标签的条件下评估已学习的表示 (Garrido et al., 2023)。行列式点过程偏好方向互补的子集 (Kulesza & Taskar, 2012)。两者都为训练任务模型之前比较源数据池提供了思路。不过，几何目标与保留低目标损失候选并不相同：某些变化可能对具体任务没有帮助，而任务重要方向可能仅占表示空间的一部分。本文将合并有效秩和明确指定的子空间 DPP 实现作为目标无关对照。

2.2 最优设计与分布匹配

A-optimal 设计通过协方差矩阵的迹衡量不确定性，并被用于主动线性回归 (Fontaine et al., 2021)。用目标特征矩加权该协方差，可以使准则侧重预期目标群体上的预测。分布匹配采用另一种思路。MMD 比较源分布与目标分布的均值嵌入 (Gretton et al., 2012)；采用齐次二次核时，这一比较由二阶矩决定。矩对齐也被用于多源域适应中的表示学习 (Peng et al., 2019)。本文固定编码器，在同一批候选组合上比较不确定性降低与矩匹配两类评分。

2.3 计算预算下的数据选择

受计算预算约束的数据选择需要同时考虑选择过程和后续训练的开销 (Yin & Rush, 2025)。数据池预筛选在其中引入一个中间决策：应当让多少组合进入监督评价？较宽的短名单可能容易构建、也能保留好候选，却仍需要较多验证工作。本文在明确的短名单规模下衡量候选保留情况，并将其与最终所选模型的质量区分开来，为进一步测量实际部署总成本提供决策层面的依据。

3 基于几何的数据池预筛选

3.1 问题与两阶段流程

设 $H_i \in \mathbb{R}^{n_i \times d}$ 为源数据池 i 的特征，由固定编码器和共享、标签无关的预处理映射得到，记 $G_i = H_i^\top H_i$ 。可行组合 S 属于有限集合 $\mathcal{C}$ ，满足 $G_S = \sum_{i \in S} G_i$ 、 $n_S = \sum_{i \in S} n_i$ 。无标签目标选择样本用于估计非中心化二阶矩 $C_T = \mathbb{E}_T[hh^\top]$ 。

预筛选对 $\mathcal{C}$ 排序，将前 s 个组合保留为 $\mathcal{Q}_s$ 。随后使用各组合的源标签训练预测器，再通过独立目标验证集选出 $\hat{S} \in \mathcal{Q}_s$ 。目标测试数据用于评价已冻结的选择和保留的候选。预筛选阶段记作 U0，只读取源特征和目标选择特征，不读取标签或验证、测试数据。监督阶段记作 U2，读取源标签和目标验证数据。目标无关规则仅使用源信息。这样的划分使预筛选能够利用可复用特征，同时把针对具体任务的证据留给最终选择。

这里的数据池是固定样本块，候选是满足约束的若干样本块的并集。我们选择的是这些并集，而不是逐张选择图像或重新训练编码器。这一区别明确了预筛选评分能够改变什么。每个保留组合都采用同一套预设分类器和验证流程，因此结果差异来自输入该流程的源样本。在等成本实验中，各组合还包含相同数量的样本。

3.2 由合并特征构造有效秩

奇异值分解 $H = U\Sigma V^\top$ 将特征方向与其强度分开。 V 的列给出编码器坐标空间中的方向， Σ 的对角元素衡量特征矩阵在这些方向上的幅度。由 $H^\top H = V\Sigma^\top \Sigma V^\top$ 可知，Gram 矩阵包含恢复它们所需的信息。它也提供了合并数据池的简便方式，无需为每个组合重新堆叠特征。

给定固定非负权重 w_i ，纵向拼接源特征可得

$$H_S = \begin{bmatrix} \sqrt{w_{i_1}} H_{i_1} \\ \vdots \\ \sqrt{w_{i_k}} H_{i_k} \end{bmatrix}, \quad H_S^\top H_S = \sum_{i \in S} w_i G_i. \quad (1)$$

因此，Gram 和能够在共享特征坐标中确定合并奇异值。保留这些算子，同时保留了每个方向的强度及其跨数据池的对应关系。若对每个组合重新中心化或拟合投影，坐标就会发生变化，需要重新计算。

我们将奇异值归一化为概率向量，再对其 Shannon 熵取指数，以此构造有效秩 (Roy & Vetterli, 2007):

$$r_{\text{eff}}(H) = \exp \left(- \sum_j p_j \log p_j \right), \quad p_j = \frac{\sigma_j(H)}{\sum_k \sigma_k(H)}, \quad (2)$$

对于非零矩阵，约定 $0 \log 0 = 0$ 以处理零奇异值。若有 ρ 个正奇异值，熵位于 0 与 $\log \rho$ 之间，因此 $1 \leq r_{\text{eff}}(H) \leq \rho$ 。秩一矩阵取得下端点，正奇异值全部相等时取得上端点。例如，两个正奇异值之比为 9:1 时，普通秩为二，有效秩却约为 1.38；两者相等时，有效秩才为二。因此，即使普通秩不变，该评分也能区分集中变化与均衡变化。

实现时，先对源 Gram 求和，计算其非负特征值，再取平方根，得到式(2)所需的奇异值。若直接归一化 Gram 特征值，就会对较强方向赋予更大权重，得到不同的评分。统一的标量缩放会在奇异值归一化时抵消。特别地，重复整个特征矩阵只会将全部奇异值乘以相同系数，有效秩保持不变。因此，它衡量谱形状，而非可供训练的带标签证据数量。数值阈值见附录B。

在概括为谱摘要之前，Gram 和中的方向信息十分重要。若仅保留各数据池的谱和子空间重叠列表，就可能已经丢失计算合并有效秩所需的信息。

命题 1 (方向分配影响合并结果). 存在行归一化的矩阵对 (A, B_1) 与 (A, B_2) ，它们具有相同的边际奇异值谱和行空间主角度，但纵向拼接后的有效秩不同。

证明. 令 A 包含四行 $e_1^\top$ 和一行 $e_2^\top$ ； B_1 包含四行 $e_1^\top$ 和一行 $e_3^\top$ ； B_2 包含一行 $e_1^\top$ 和四行 $e_3^\top$ 。三者非零奇异值谱均为 $(2, 1)$ ，两组行空间主角度均为 $(0, \pi/2)$ 。合并 Gram 谱分别为 $(8, 1, 1)$ 与 $(5, 4, 1)$ ，对应有效秩约为 2.6260 与 2.8495。□

两个合并结果向共享方向分配了不同的能量。这解释了为何本文评分使用 Gram 算子，而不仅依赖边际谱。附录A 还给出算子具有相容双方向子块时的精确局部谱公式。

3.3 目标加权与矩匹配

为将几何与预测联系起来，考虑标量贝叶斯线性回归： $\theta \sim N(0, P_0)$ 、 $P_0 \succ 0$ ，且 $y = h^\top \theta + \epsilon$ ，独立噪声满足 $\epsilon \sim N(0, \sigma^2)$ 、 $\sigma^2 > 0$ 。源与目标共享 θ 和噪声模型，目标协变量不再提供关于 θ 的额外信息。给定源设计矩阵，后验协方差与后验均值的目标预测风险为

$$P_S = (P_0^{-1} + \sigma^{-2} G_S)^{-1}, \quad R_T(S) = \sigma^2 + \text{tr}(C_T P_S). \quad (3)$$

这里的期望同时平均后验不确定性与新目标观测，推导见附录A。

式(3)引出评分 $f_A(S) = \text{tr}(\hat{C}_T P_S)$ ，在固定超参数下取其最小值。源观测降低其所覆盖方向上的不确定性，目标二阶矩则按预测时这些方向的出现程度赋予权重。因此，即使一个数据池的总体多样性不高，只要它覆盖了尚不确定且对目标重要的方向，也可能具有价值。增加半正定源 Gram 不会使该分数增大。

实验采用 $P_0^{-1} = I$ 和 $\sigma^2 = 1$ 。将 G_S 写为 $U \text{diag}(\lambda_j) U^\top$ ，并包含零特征值对应的方向，可得

$$f_A(S) = \sum_j \frac{u_j^\top \hat{C}_T u_j}{1 + \lambda_j}. \quad (4)$$

分母反映源数据对方向 u_j 的覆盖，分子衡量该方向对目标的重要性。因此，即使两个组合的特征值相同，只要其方向与目标的对齐方式不同，也可以得到不同分数。有效秩对相同谱一视同仁，目标加权则区分这些覆盖在哪里有用。

二阶矩匹配则最小化

$$f_M(S) = \left\| G_S/n_S - \hat{C}_T \right\|_F^2. \quad (5)$$

它对应核 $k(h, h') = (h^\top h')^2$ 下包含对角项的经验 MMD 平方。它直接使源数据的平均方向能量接近目标，而不是对后验不确定性矩阵加权。两种准则读取相同特征，因此二者比较检验的是：相对直接矩匹配，逆协方差加权能否提供额外价值。

共享条件模型是 A-opt 风险解释的依据，这一假设有实际含义。例如，所有特征均为 1，两个源数据池的标签分别恒为 +1 和 -1；当两个目标世界的常数标签相反时，源预测器的风险排序随之反转，而特征几何完全不变。因此，在分类实验中，我们使用训练后的 ridge-softmax 和逻辑回归读出器评价这些分数，而不将式(3)直接视为分类损失。

3.4 区分候选保留与最终选择

设 $\ell(S)$ 为固定已训练预测器的目标风险， $v(S)$ 为验证损失。若全部 $S \in \mathcal{Q}_s$ 满足 $|v(S) - \ell(S)| \leq \varepsilon$ ，则验证最优选择满足

$$\ell(\hat{S}) - \min_{S \in \mathcal{C}} \ell(S) \leq \underbrace{\min_{S \in \mathcal{Q}_s} \ell(S) - \min_{S \in \mathcal{C}} \ell(S)}_{\text{短名单遗漏}} + 2\varepsilon. \quad (6)$$

证明见附录A。第一项关心预筛选是否丢弃了最佳可用选择，第二项关心如何在保留集合内部选择。即使短名单包含最优候选，若验证排序不同，最终模型仍可能较差。我们审计这些量在有限测试集上的对应值，并测量测试前十名召回率，考察是否有多个好候选通过筛选。上述偏差条件用于解释两类误差来源，实验没有将其估计为总体风险保证。

4 评价协议

受控合成任务检验风险模型。随后在 PACS 和 Office-Home 上，以预先指定的实质效应门槛评价直接选择 (Li et al., 2017; Venkateswara et al., 2017)，并在这些结果之后开展穷举改善空间分析。后续 DomainNet 研究固定样本成本、评价短名单，其配置在特征提取和结果评价前冻结。测试样本重采样及之后的投影、读出器实验属于探索性补充分析。附录B 记录配置和结果位置。

我们从官方 cleaned DomainNet 数据中 (Peng et al., 2019) 按固定哈希规则选择 100 个类名。六个域各自提供互不重叠的 1,536 张目标选择图像、1,024 张目标验证图像和 3,072 张锚点池图像，均取自官方训练集，另有 2,048 张官方测试图像。manifest 共含 46,080 张图像。类别元数据用于定义基准词表，但不向预筛选开放。

CLIP ViT-B/32 (Radford et al., 2021) 作为冻结的构造锚点。各域内部按其第一主成分分数划分低、中、高三个层次，每层提供一个包含 512 张图像的块。对给定目标，排除其自身数据块，从剩余块中穷举 $\binom{15}{3} = 455$ 个组合，每个包含 1,536 张源图像。ResNet-50 和 DINOv2-B/14 提供评价特征 (He et al., 2016; Oquab et al., 2024)。全部规则共享行归一化、固定的 128 维 Rademacher 投影及投影后行归一化。固定样本数量消除了候选训练成本差异的一个直接来源。

Target A-opt 使用 $P_0^{-1} = I$ 和 $\sigma^2 = 1$ 。对照包括二阶矩 MMD、目标能量 $\text{tr}(\hat{C}_T G_S/n_S)$ 、Bayesian D-opt、合并有效秩、子空间 DPP、域平衡以及 20 个固定种子的随机排序。所有规则评价相同候选族。域平衡额外读取源域标识。核定义和并列规则见附录B。

预筛选生成大小为 10, 25, 50, 100, 227 的嵌套短名单，以 227 为主设置。原协议的 U2 阶段独立评价每种方法的主短名单，采用正则化为 1、无截距、固定 softmax 温度的岭回归。验证 Brier 最小的组合为最终选择，平局按字典序处理。较小短名单复用同方法的嵌套评价，不共享跨方法缓存。测试阶段先核验上游哈希，再评价全部组合，建立穷举审计参照。

补实验新增四个投影种子和固定正则化的多项逻辑回归，保持候选成员与数据角色不变。筛选、验证和测试仍由独立进程执行，但不同方法复用同一组合的拟合模型来审计各自短名单。因此，该运行时间反映的是缓存研究审计的成本，而非各方法分别部署的成本。读出设置和来源核验见附录B。

我们衡量有多少测试前十名候选通过筛选，以及验证选择与经验最优的差距。记测试 Brier 为 $b(S)$ 、穷举最优组合为 S^* ，两者定义为

$$\text{Recall}_{10}(Q_s) = \frac{|Q_s \cap \text{Top}_{10}(b)|}{10}, \quad \text{Regret}(\hat{S}) = \frac{b(\hat{S}) - b(S^*)}{|b(S^*)|}. \quad (7)$$

原主判据要求至少移除 50% 的组合、平均召回率至少 90%、平均归一化遗憾至多 5%。Brier 为主指标。补充的 NLL 和分类错误率审计分别使用对应验证指标选择候选，并在访问测试数据之前固定指标。

首先在每个数据集-目标域内平均编码器，在任务内平均随机排序。PACS/Office-Home 共八个这样的单位，DomainNet 共六个。补实验种子同样在域内平均。原 bootstrap 区间对目标单位重采样；测试样本分析则固定训练模型，在各目标内部重采样图像。种子、编码器和重叠组合是重复测量，而不是新增的独立数据集。

5 实验结果

5.1 共享风险模型下的目标加权

合成研究改变特征维度、候选数量、源预算、目标样本数及目标秩，对 216 个设计设置分别使用 20 个生成种子。在共享条件模型下，A-opt 相对最强目标无关有效秩对照降低模型风险 4.23%，相对 MMD 降低 14.85%。对应的描述性 95% 区间为 [3.86, 4.62]% 与 [13.99, 15.70]%，先平均种子，再对设计设置重采样。这些比较表明，当支撑该操作的模型成立时，按目标对不确定性加权具有收益。

另一组源条件偏移实验改变回归机制，其平均归一化预测遗憾从无偏移时的 0.211 增至最大测试偏移下的 3.143。这一终点评价实际预测，而非后验风险。两组研究分别考察了覆盖目标相关方向的收益，以及跨不同条件机制迁移标签的影响。

5.2 直接选择与可用改善空间

PACS 和 Office-Home 实验考察评分能否直接选出更好的源组合。在块预算 $K = 3$ 时，A-opt 相对 DPP 和 MMD 的单位内相对 Brier 改善均值分别为 0.351% 和 0.273%，均未达到预设的 2% 实质效应门槛。配对差值区间相对 DPP 跨越零，相对 MMD 则为负；完整数值见附录 C。这些比较固定块数，而非源样本数。

为理解可实现收益的尺度，事后审计评价全部可行组合。图2 显示，即使测试 oracle 相对 DPP 的平均改善空间也只有 0.781%。因此，大多数目标单位留给其他选择器的平均损失改善空间有限。这促使我们将候选保留作为单独问题考察：即使最终选择的损失相近，几何信息仍可能帮助缩小搜索范围。

5.3 保留有希望的等成本组合

表1 比较原 DomainNet 实验的短名单。A-opt 在移除约一半组合的同时，保留了几乎全部测试前十名候选。所有主设置短名单都包含测试 Brier oracle，剩余选择遗憾来自验证阶段选取了其他成员。这正是式(6) 的区分：预筛选成功后，验证仍有独立任务需要完成。

MMD 与 A-opt 的主设置召回率和选择遗憾相同，并在每个编码器-目标任务中经验证阶段选出同一最终组合。在更小短名单上，MMD 的平均召回率更高（图1）。因此，A-opt 更高的完整排序相关性，并没有转化为这些工作点上更好的候选保留。两者相对已测目标无关规则的共同优势，表明目标条件二阶信息具有价值；在这里，直接矩匹配已经是利用该信息的有效方式。

5.4 投影与读出器敏感性

原 ridge-softmax 实验的候选损失差异较小。因此，我们进一步考察：改变投影，并使用产生更宽损失范围的读出器后，高召回是否仍然存在？探索性补实验新增四个投影种子和逻辑回归，保持源成员和样本成本固定。表2 报告新种子均值；原种子单独用作实现对照。

A-opt 在两种读出器下的 Brier 前十名平均召回均为 98.33%，MMD 略高。平均相对 Brier 最好到最坏跨度从 ridge-softmax 的 0.248% 增至逻辑回归的 14.65%。这表明，高召回在候选差

表 1: 原 DomainNet 实验从 455 个组合中保留 $s = 227$ 个。均值先在六个目标域内平均编码器。召回率对应测试 Brier 前十名; 遗憾相对于 oracle Brier; Spearman 衡量完整筛选排序与测试损失排序的一致性。

Screen	Recall (%)	Regret (%)	Spearman
Target A-opt	98.333	0.001311	0.7443
Second-moment MMD	98.333	0.001311	0.6902
Bayesian D-opt	82.500	0.002658	0.4996
Merged effective rank	81.667	0.002909	0.4951
Random (20 repeats)	48.958	0.003899	0.0016
Target energy	46.667	0.009347	-0.0399
DPP subspace	27.500	0.009067	-0.0633
Domain balance	25.000	0.012083	0.0681




图 1: 图中展示原 DomainNet 实验的测试 Brier 前十名平均召回率如何随短名单规模变化。虚线为预设召回门槛。全部曲线使用相同候选组合, 各规则按其对应权限读取特征。

异更明显时仍然存在, 并不只出现在 Brier 损失几乎相等的设置中。两种目标感知评分也平均保留了大部分按 NLL 和错误率排序的优质候选, MMD 在这些比较中同样较高。

在 Brier 指标下, 两种方法在所有新种子任务中都保留了测试 oracle, 平均选择遗憾也相同。不过, 均值并不能代表每个任务: 在一个 DINOv2–Quickdraw 逻辑回归任务中, A-opt 的分类错误率前十名召回降至 40%。该短名单仍包含测试错误率 oracle, 但验证所选模型的错误率高出 1.66 个百分点。这说明, 应分别报告广泛候选保留、特定指标下的保留, 以及最终选择。完整对照表和任务细节见附录 C。

5.5 损失分辨能力与测试样本稳定性

图 2 的事后损失跨度诊断为理解原遗憾判据提供了参照。所有候选的相对 Brier 遗憾都低于 5%, 因此该门槛无法在本实验中区分筛选是否成功。召回率提供了更有信息量的比较, 但也引出另一个问题: 测试前十名对测试样本的抽取有多敏感?

CUDA 重建首先复现了原实验的全部 Brier 前十名集合。随后固定拟合模型和验证选择, 对测试样本进行配对 bootstrap。重采样与原前十名集合平均仅重叠 85.15%, 但 A-opt 和 MMD 仍分别保留重采样前十名的 97.42% 和 97.85%。在这些测试样本变化下, 较宽短名单比精确排名成员更稳定。

改变指标对“哪些组合算好”的影响更大: 原实验 Brier 与分类错误率前十名平均仅重叠 29.17%。因此, 即使预筛选在若干指标上都有较高平均召回, 仍应按预期部署指标评价。重采样协议与其他指标比较见附录 B。

表 2: 探索性 DomainNet 补实验评价大小为 $s = 227$ 的短名单。测试前十名召回率 (%) 先在每个目标域内平均两个编码器和四个新投影种子, 再对六个域平均。Ridge 指 ridge-softmax; NLL 和错误率分别使用对应验证损失作最终选择。

Readout	Metric	A-opt	MMD	Random
Ridge	Brier	98.33	99.38	50.12
Ridge	NLL	98.54	99.38	49.86
Ridge	Error	96.25	97.50	48.63
Logistic	Brier	98.33	98.96	48.97
Logistic	NLL	98.54	99.79	48.61
Logistic	Error	97.29	97.92	49.04




图 2: 两个面板报告不同候选族的事后诊断。左图展示各 PACS/Office-Home 目标内平均编码器后, oracle 相对 DPP 的 Brier 改善空间。右图展示原 DomainNet 任务的相对 Brier 最好到最坏跨度。原评价门槛保持不变。

6 讨论

6.1 何时值得预筛选?

实验提示, 应根据预筛选所服务的决策评价其价值。当候选族本身改善空间很小时, 最终损失差异较小, 并不足以说明排序优劣。当候选差异更明显时, 保留多个有希望的组合, 可以给验证阶段留下针对任务选择的空间。在已审计的 DomainNet 构造中, A-opt 与 MMD 都较好地完成了这一任务; 二者相近的结果也说明, 矩匹配是评价更复杂几何评分时的重要基线。

合适的工作点取决于目标指标、可接受的损失差距, 以及监督评价的成本。短名单规模决定有多少候选进入下一阶段, 总节省还取决于评分、特征准备和验证开销。此外, 附录C中的草图实验表明, 有效分数区间仍可能过宽, 无法在有用的字节预算下确定选择。压缩后的评分若要支撑筛选, 就仍须在预期短名单预算下区分候选。

6.2 局限性

等样本成本证据来自一种 DomainNet 构造。目标域之间共享源数据池, 新增种子与读出器也复用相同图像。它们衡量的是基准内部敏感性, 而非独立数据上的复现。相对 PACS/Office-Home, 数据集、投影、样本预算和候选构造均有变化, 因此不能单独识别候选异质性的因果作用。

贝叶斯推导针对共享线性回归，分类结果则从经验上评价其评分的作用。测试样本重采样以拟合模型和验证选择为条件，不衡量训练或验证选择带来的不确定性。绝对任务质量也取决于候选族，补充适配器实验提供了例子。最后，本文尚未测量匹配的端到端节省，也未排除与编码器预训练数据的重叠。独立等成本数据集、受控验证预算和匹配计时比较可以进一步回答这些问题。

7 结论

本文建立了在监督验证前利用特征几何筛选源数据池组合的两阶段协议。分析解释了共享线性模型下目标加权如何联系源覆盖与风险，并区分预筛选遗漏和最终选择误差。实验在不同投影种子与读出器下，均观察到对等成本 DomainNet 组合的高候选保留；二阶矩匹配在工作点上与 A-optimal 筛选同样有效。PACS 和 Office-Home 的直接选择结果则表明，可用改善空间同样重要。这些发现支持用目标感知几何缩小搜索范围，再以任务证据作最终决定。同时测量这一决定的质量与完整评价成本，是进一步确定有用筛选预算的方向。

AI 使用声明

生成式 AI 工具参与了概念重构、数学命题与证明草拟、实验设计、软件实现、结果解释、文献检索、论文写作、绘图脚本编写及中文翻译。本稿数值发现来自自己记录的实验产物，而非生成的观测值。AI 辅助不构成对实验产物或数学主张的独立验证。提交版本的最终核验与责任仍由人类作者承担。

可复现性声明

附录A 给出证明细节；第4节和附录B 给出预处理、访问规则、候选构造、指标与结果路径。代码仓库为 <https://anonymous.4open.science/r/collapsemodel-1DB6>。结果表和 manifest 支持汇总复现；大型特征缓存通过哈希标识，不重复存入 Git。我们不声称不同硬件能够逐位复现全部特征。

伦理声明

研究使用既有基准图像及预训练编码器，不新增参与者招募。公开可用并不消除图像许可、隐私或表示偏差问题。我们不声称多样的特征谱或高短名单召回率意味着所选数据池在社会层面具有代表性、公平性或隐私保护。候选类别体系、预训练重叠不确定性及视觉分类限制了下游部署主张。数据集和模型访问仍须遵守其原有条款。

参考文献

- Koenraad M. R. Audenaert. A sharp continuity estimate for the von Neumann entropy. *Journal of Physics A: Mathematical and Theoretical*, 40(28):8127–8136, 2007. doi: 10.1088/1751-8113/40/28/S18.
- Xavier Fontaine, Pierre Perrault, Michal Valko, and Vianney Perchet. Online A-optimal design and active linear regression. In *International Conference on Machine Learning*, pp. 3374–3383, 2021. URL <https://proceedings.mlr.press/v139/fontaine21a.html>.
- Quentin Garrido, Randall Balestriero, Laurent Najman, and Yann LeCun. RankMe: Assessing the downstream performance of pretrained self-supervised representations by their rank. In *International Conference on Machine Learning*, pp. 10929–10974, 2023. URL <https://proceedings.mlr.press/v202/garrido23a.html>.
- Arthur Gretton, Karsten M. Borgwardt, Malte J. Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *Journal of Machine Learning Research*, 13(25):723–773, 2012. URL <https://www.jmlr.org/papers/v13/gretton12a.html>.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016. URL <https://arxiv.org/abs/1512.03385>.
- Alex Kulesza and Ben Taskar. Determinantal point processes for machine learning. *Foundations and Trends in Machine Learning*, 5(2–3):123–286, 2012. doi: 10.1561/22000000044. URL <https://arxiv.org/abs/1207.6083>.
- Da Li, Yongxin Yang, Yi-Zhe Song, and Timothy Hospedales. Deeper, broader and artier domain generalization. In *IEEE International Conference on Computer Vision*, 2017.
- Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. URL <https://arxiv.org/abs/2304.07193>.

- Xingchao Peng, Qinxun Bai, Xide Xia, Zijun Huang, Kate Saenko, and Bo Wang. Moment matching for multi-source domain adaptation. In *IEEE/CVF International Conference on Computer Vision*, pp. 1406–1415, 2019. URL https://openaccess.thecvf.com/content_ICCV_2019/html/Peng_Moment_Matching_for_Multi-Source_Domain_Adaptation_ICCV_2019_paper.html.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pp. 8748–8763, 2021. URL <https://proceedings.mlr.press/v139/radford21a.html>.
- Olivier Roy and Martin Vetterli. The effective rank: A measure of effective dimensionality. In *15th European Signal Processing Conference*, pp. 606–610, 2007. URL <https://infosciences.epfl.ch/bitstreams/2907ab8a-23f5-481d-bb07-1d56a3f3511f/download>.
- Hemanth Venkateswara, Jose Eusebio, Shayok Chakraborty, and Sethuraman Panchanathan. Deep hashing network for unsupervised domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 5018–5027, 2017.
- Junjie Oscar Yin and Alexander Rush. Compute-constrained data selection. In *International Conference on Learning Representations*, 2025. URL https://proceedings.iclr.cc/paper_files/paper/2025/hash/5acb720a361eecb34ee62d356859d246-Abstract-Conference.html.

A 证明与数学主张的适用范围

设 u, v 为单位方向, $u^\top v = c \in [0, 1]$ 。在正交基 u, z 中写成 $v = cu + \sqrt{1-c^2}z$, 算子 $a^2uu^\top + b^2vv^\top$ 表示为

$$\begin{pmatrix} a^2 + b^2c^2 & b^2c\sqrt{1-c^2} \\ b^2c\sqrt{1-c^2} & b^2(1-c^2) \end{pmatrix}. \quad (8)$$

其迹为 $a^2 + b^2$, 行列式为 $a^2b^2(1-c^2)$, 因此特征值为

$$\lambda_{\pm} = \frac{a^2 + b^2 \pm \sqrt{(a^2 - b^2)^2 + 4a^2b^2c^2}}{2}. \quad (9)$$

当 $c = 1$ 时, 第二分支为零。若相关子块相互正交, 且对两个源 Gram 都是不变子空间, 汇集这些特征值对便得到完整谱; 未配对方向贡献自身特征值。这一相容条件不可省略, 因为主向量不必是奇异向量。

固定 H_S 并采用高斯似然, 对先验与似然乘积完成平方可得后验精度 $P_0^{-1} + \sigma^{-2}H_S^\top H_S$ 和均值 $\mu_S = P_S\sigma^{-2}H_S^\top y_S$ 。对独立目标观测 $y = h^\top\theta + \epsilon$, 给定训练数据与 h , 有

$$\mathbb{E}[(y - h^\top\mu_S)^2 \mid H_S, y_S, h] = \sigma^2 + h^\top P_S h. \quad (10)$$

对 h 积分得到式(3)。这里假设目标协变量分布不会在该模型之外额外透露关于 θ 的信息。若源数据具有不同回归函数, 或标签为多分类且采用 softmax 读出, 则该推导不再等于所评价的损失。证明不约束这种模型误差。以有限样本估计替代 C_T 还引入另一类偏差, 恒等式也不会自动消除它。

若 $G \succeq \tilde{G} \succeq 0$, 逆矩阵序给出 $(P_0^{-1} + \sigma^{-2}G)^{-1} \preceq (P_0^{-1} + \sigma^{-2}\tilde{G})^{-1}$ 。与 PSD 目标矩相乘取迹保持该顺序。更一般地, 若遗漏草图尾部之和满足 $0 \preceq G - \tilde{G} \preceq \delta I$, 定义 $B = P_0^{-1} + \sigma^{-2}\tilde{G}$, 则

$$\text{tr}(\hat{C}_T(B + \sigma^{-2}\delta I)^{-1}) \leq f_A(G) \leq \text{tr}(\hat{C}_T B^{-1}). \quad (11)$$

各 PSD 尾部的有效谱范数上界之和, 是一种可取的 δ 。当某候选上界低于所有竞争者下界时, 可以认证该候选的代理排序。因此, 除了覆盖率, 区间宽度也决定草图能否支撑下一次选择。归档扫描使用其文档中的字节计数, 评价这类代理比较。

令 S_Q 在 $\mathcal{Q}_s$ 中最小化 ℓ 。短名单上的一致偏差给出

$$\ell(\hat{S}) \leq v(\hat{S}) + \varepsilon \leq v(S_Q) + \varepsilon \leq \ell(S_Q) + 2\varepsilon. \quad (12)$$

减去 $\min_{S \in \mathcal{C}} \ell(S)$ 即得式(6)。该代数推导没有给出概率声明。若要获得总体泛化保证, 必须结合真实依赖与选择流程另外证明偏差事件。有限测试集上的穷举分数本身不足以提供这种证明。

映射 $\phi(h) = hh^\top$ 采用 Frobenius 内积, 满足 $\langle \phi(h), \phi(h') \rangle_F = (h^\top h')^2$ 。源与目标经验特征均值之间的平方距离即式(5)。这是有偏经验平方 MMD, 即 V 统计量, 而非去掉对角项的无偏估计。它依赖非中心化二阶矩, 无法区分所有具有相同二阶矩的分布。我们将其作为计算简单的同信息对照, 而非完备分布差异度量。

B 实现与审计细节

原 DomainNet 实验拟合岭回归读出, 并将其分数转换为类别概率。权重与 Brier 损失为

$$\begin{aligned} W_S &= (I + G_S)^{-1} \sum_{i \in S} H_i^\top Y_i, & p(x) &= \text{softmax}(h(x)^\top W_S), \\ b(S) &= \frac{1}{n_T} \sum_t \|p(x_t) - e_{y_t}\|_2^2. \end{aligned} \quad (13)$$

Y_i 为固定 100 类词表下的源 one-hot 标签矩阵。不使用截距或温度调参。载入 float32 特征后, 线性代数以 float64 计算。通过 Gram 特征分解计算有效秩时, 先将负舍入特征值裁剪为零, 再取平方根得到奇异值, 仅保留 $\sigma_j > \sigma_{\max} \sqrt{8\epsilon_{64} \max(n_S, d, 1)}$ 。代码对零矩阵返回零秩。该阈值针对数值秩, 不改变熵定义。共享投影种子为 20260911, 维度为 128; 冻结 DomainNet 协议内部没有根据结果选择维度。

Bayesian D-opt 最大化 $\log \det(I + G_S)$ 。子空间 DPP 取每个块的前 16 个 Gram 特征向量 U_i ，定义 $K_{ij} = \|U_i^\top U_j\|_F^2 / 16$ ， $K_{ii} = 1$ ，将其数值投影到 PSD 相关矩阵，再最大化 $\log \det(K_{S,S} + 10^{-8}I)$ 。该核描述块子空间，而非单图像特征。域平衡最大化已覆盖域数量，减去各域块数平方和的 10^{-3} 倍。确定性分数按组合标识字典序处理并列。这些是固定对照；该 DPP 构造表现不佳，不是对所有行列式选择方法的结论。

DomainNet 记录图像内容哈希、样本标识、官方划分、角色及类别词表。特征提取前验证归档与划分校验和。角色互斥和重复内容检查处理已物化基准内部的重叠，但不能排除语义近重复或预训练污染。全部筛选方法使用相同源块、投影、目标选择行和候选集合。特征提取忽略标签，基准物化则使用类别元数据，并为后续授权阶段存储标签。

筛选、验证与审计 manifest 绑定配置和上游产物哈希，分阶段加载器执行标签与划分权限。原协议的验证阶段单独评价每种方法或随机重复。选择冻结后，测试审计覆盖每个编码器的全部 6×455 个组合，穷举 oracle 作为研究参照。补实验的缓存策略如下。

CUDA 重建保留原样本标识、候选成员、预处理和超参数，全部十二个 Brier 前十名集合与原实验一致。逐样本损失均值与重建聚合审计的误差不超过 1.78×10^{-15} 。每个目标域对其 2,048 个测试样本执行 2,000 次配对 bootstrap，全部组合、编码器和四种损失共享权重。拟合模型与验证选择固定，平局按组合标识处理。这些重采样衡量对测试样本抽取的敏感性。原 Brier 前十名与 NLL、原始平方损失及分类错误率前十名的平均重叠分别为 90.83%、30.83% 和 29.17%。

种子 20260917、20260918、20260919、20260920 生成新的 128 维 Rademacher 投影，保持投影前后行归一化。种子 20260911 用作实现对照，不计入新种子均值。逻辑回归采用 L2 正则化、 $C = 1$ 、无截距、LBFGS，容差为 10^{-6} ，最多迭代 1,000 次。若出现收敛警告则终止任务；实际没有出现警告，最大迭代次数为 24。类别词表固定，源数据中缺失类别的概率设为零。

所有方法保留原筛选规则、候选组合和五种短名单规模，由独立进程依次筛选、拟合验证、测试冻结模型。测试特征读取前，核验源码、配置、来源、模型及选择的哈希。每个读出器对全部组合拟合一次，各方法复用这些拟合结果。这种缓存穷举评价用于比较不同短名单的反事实结果。Brier、NLL 和错误率分别使用自己的验证损失作最终选择。原种子岭回归在 5,460 个重建测试组合上的最大损失差异为 1.78×10^{-15} ，全部 1,620 个 Brier 验证选择完全一致。

两个编码器、五个种子、两种读出器合计完成 54,600 次拟合。新种子汇总先在任务内平均随机重复，再在目标域内平均编码器和种子，最后平均六个域。每个读出器包含 48 个编码器-种子-目标域重复测量，但仍是共享相同源池的六个目标域单位。

归档保留历史实验编号用于定位结果，不应将其与论文科学问题混淆。以下路径相对于匿名代码仓库：

- 共享模型与偏移研究 (E1): `results/target_conditioned/e1_synthetic/expanded_v3_controlled_rng/`。
- PACS/Office-Home 对照 (E2): `results/target_conditioned/e2_dataset_selection/method_v1/`。
- 事后改善空间 (E2a): `results/target_conditioned/e2_dataset_selection/oracle_headroom_v1/`。
- 等成本短名单 (E2b): `results/target_conditioned/e2b_fixed_cost_shortlist/domainnet_v1/`。
- 风险草图扫描 (E5): `results/target_conditioned/e5_sketch_certificate/expanded_v3_controlled_rng/`。
- 重建与测试重采样 (R1/R2): `results/target_conditioned/revision_20260916/`。
- 投影与读出器补实验 (R3/R4): `results/target_conditioned/revision_20260917/`。

DomainNet 数据 manifest 前缀为 `1ba25059df70be4d`，候选集 ID 前缀为 `545fe86c8c9e8304`，汇总 ID 前缀为 `2d473cb9eb977e85`；完整 SHA-256 位于产物中。原配置为 `code/configs/target_conditioned_e2b/domainnet_v1.json`，实现

为 `scripts/run_target_conditioned_e2b_shortlist.py`。补实验采用 `code/configs/target_conditioned_e2b/readout_projection_v1.json` 和 `scripts/run_e2b_readout_projection.py`，汇总表位于 `R3/R4` 目录内的 `revision_results/e2b_readout_projection_v1/summary/`。论文的 `build_assets.py` 从记录的源文件生成表格、图、数字宏和双语摘要，完整输入哈希记入 `generated/asset_manifest.json`。

三份原始特征矩阵未重复存入 Git。元数据记录精确文件哈希、检查点哈希、形状、预处理、提取代码版本和运行环境。重新提取需要原始公开数据及模型权重，不假设不同硬件逐位一致。仓库保留 `manifest` 和足够的结果表，可在没有这些矩阵时复现报告的汇总结果。

C 补充结果

PACS/Office-Home、 $K = 3$ 时，A-opt 平均 Brier 为 0.826769，DPP 为 0.829162，MMD 为 0.828719。A-opt 减去基线的配对区间分别为 $[-0.007449, 0.000731]$ 和 $[-0.003392, -0.000712]$ 。事后审计覆盖每个任务全部 220 个组合。Oracle 相对 DPP 的改善空间描述性 95% 区间为 $[0.162, 1.617]\%$ ；仅 PACS photo 在目标单位层面超过原 2% 门槛。相对父方法的事后测试最优包络，oracle 平均还能改善 0.087%。该包络是基于结果的参照，不是可用于选择的基线。

表3 给出主规模下完整的 Brier 召回比较。A-opt 和 MMD 平均相对选择遗憾相同：岭回归为 0.001006%，逻辑回归为 0.103%。两者全部新种子主设置 Brier 短名单均包含经验 oracle。

表 3: 表中报告全部补实验评分规则在 $s = 227$ 时的 Brier 前十名召回率 (%)。平均方式与表2 相同，不包括原种子对照。

Screen	Ridge	Logistic
Target A-opt	98.33	98.33
Second-moment MMD	99.38	98.96
Bayesian D-opt	82.29	86.46
Merged effective rank	80.42	85.42
Random (20 repeats)	50.12	48.97
Target energy	41.04	33.96
DPP subspace	28.75	35.42
Domain balance	26.46	31.67

A-opt 最低分类错误率召回出现在 DINOv2、Quickdraw、逻辑回归、投影种子 20260918 的任务中。测试错误率 oracle 为 85.9863%，验证选择为 87.6465%。虽然前十名召回只有 40%，短名单仍保留 oracle。因此，保留最佳成员与保留前十名回答不同问题，二者也都不同于可用模型的绝对质量。

四编码器、十个构造种子的谱扫描使用六个重叠设置和四种预算，每个草图秩有 960 个配置。秩为 10, 20, 50 时，相对仅使用秩的对照，Gram 草图在精确合并有效秩上的收益分别为 2.09, 3.81, 4.94%，DPP 为 4.90, 5.48, 5.68%。这些是几何目标收益，不是分类准确率。熵连续性界采用 Audenaert (2007) 这一类型的界；2,880 个已选择前缀区间全部覆盖，但 7,200 个评价的贪心步骤没有一步得到认证。结果来源为 `results/two_stage_controlled_rank_sweep_corrected_v3/`。这并不意味着所有低秩草图都必然失败。

独立 E5 研究将草图载荷与紧凑对称 float64 Gram 比较，而非与更大的稠密存储比较。在覆盖完整网格、平均字节比不超过 25% 的策略中，与 Full-Gram 贪心的最佳所选集合一致率为 15.42%，由自适应秩上限 2 获得，平均字节比为 14.91%。其成对证书率为 3.91%，完整选择认证率为零。自适应回退能够实现完全所选集合一致，但计入此前传输后，平均成本约为紧凑 Gram 字节的 160%，未达到决策与通信的联合要求。参照是 Full-Gram 贪心，而非穷举全局最小解。

另一项早期实验在 21 个来源上训练源监督 bottleneck adapter，使用四个编码器、五个 adapter 种子审计七个目标。目标训练内验证采用三个分层五折划分，选择冻结后独立读取 held-out 目标测试集。冻结 identity 平均准确率为 0.83654，未训练随机 adapter 为 0.77144，验证 oracle 源监督 adapter 为 0.76951。后者比 identity 低 0.06703，目标聚类 95% 区间为

[−0.09771, −0.04400]。相对该 adapter 族的小短名单遗憾因而不代表下游收益。这不是 DomainNet 实验，也不是对所有适应方法的否定。结果位于 results/two_stage_repeated_cv_utility_corrected_v3/。