

特征几何用于数据池预筛选：效用、稳定性与局限

Anonymous authors

Paper under double-blind review

ABSTRACT

为目标任务选择源数据池，可能需要针对许多数据池组合分别训练和验证预测器。冻结特征允许更早比较候选，但保留好候选本身还不够：最终选择的质量与节省的工作必须能够说明预筛选的价值。本文评价一个两阶段协议，先用无标签源特征和目标特征形成短名单，再用源标签训练预测器，通过目标验证选出一个。我们比较目标加权实验设计 (A-opt)、二阶矩匹配 (MMD) 和目标无关多样性。分析在共享线性模型下解释实验设计评分，并区分候选遗漏与验证误差。在固定样本成本的 DomainNet 组合上，评价 50 个 A-opt 或 MMD 候选的平均测试 Brier 低于评价 227 个随机候选。探索性地改变投影和读出器后，矩匹配仍有竞争力。固定参数重新分块后，域级匹配同样表现良好，而域内收益取决于构造和损失指标。PACS 和 Office-Home 的直接选择收益较小，可用改善空间也有限。独立计时表明，已有特征缓存时可以节省计算。加入实测特征提取成本后，逻辑回归仍有节省，岭回归的收益则发生反转。这些结果从最终选择质量和计算成本评价预筛选，而不只看候选保留率。

1 引言

将预测器用于一个目标域时，研究者往往有多个源数据池可供选择。这些数据池的采集条件、图像风格或样本覆盖范围可能不同。比较组合的一种做法，是分别训练预测器，再在目标验证数据上评价。即使单个预测器很小，反复执行这一过程也会产生成本。本文的问题是：能否通过更早的比较，减少需要监督评价的组合，同时不丢弃有用的选择？

预训练编码器提供了比较候选的共同空间。编码器将每张图像映射为特征向量；保持其参数不变，这些特征就能在源组合和分类器拟合之间复用。CLIP、DINOv2 等表示使这种设置具有现实基础 (Radford et al., 2021; Oquab et al., 2024)。在固定特征上训练的分类器称为读出器。在拟合它之前，可以先比较源数据池覆盖了哪些特征方向，以及这些覆盖与目标的关系。

覆盖广本身并不能说明对目标有用。有效秩通过对归一化奇异值的熵取指数，概括变化是否均匀分布在不同方向上 (Roy & Vetterli, 2007; Garrido et al., 2023)。较高的数值可能来自预测时很少遇到的变化，各自多样的数据池也可能大幅重叠。因此，源多样性与目标相关性是不同的问题。使用目标特征的评分，能够区分仅凭源谱摘要无法区分的方向。

几何仍然不能消除预测中的不确定性：特征覆盖本身不能决定特征与标签的关系。因此，本文用几何保留备选，再用带标签验证从中选择。这里有两个不同的问题：预筛选是否留下了好候选，验证是否从保留集合中选出了好的预测器？排序是否有用，最终要通过所选模型和获得这一选择所需的工作来判断。

本文评价一个两阶段数据池预筛选协议。无标签源特征和目标特征先对组合排序，随后在保留的源组合上训练预测器，并用独立目标验证数据选择。目标加权实验设计偏好能够降低目标相关方向上不确定性的覆盖 (Yu et al., 2006)，二阶矩匹配则比较源数据的平均方向能量与目标的差异。本文将这些评分与目标无关多样性对照，区分筛选遗漏和验证误差，并在不同评价预算与计算成本下测量最终损失。

在固定样本成本的 DomainNet 组合上，较短几何名单的平均测试 Brier 低于较长随机名单；Brier 用于衡量概率预测损失。独立计时表明，已有特征缓存时可以节省计算；加入实测特征工作后，逻辑回归仍有节省，岭回归的收益则反转。源域对照和固定参数重新分块区分了有用的块信息与域级匹配，结果随构造和指标变化。改变投影与读出器后仍有较高平均召回，而 PACS 和 Office-Home 留给直接选择方法超越基线的空间有限。这些比较共同评价目标感知几何对监督数据池选择的作用，以及它的额外工作在何时值得付出。

2 相关工作

2.1 最优设计与分布匹配

A-optimal 设计通过协方差矩阵的迹衡量不确定性，并被用于主动线性回归 (Fontaine et al., 2021)。Transductive experimental design 最小化给定目标协变量上的预测方差 (Yu et al., 2006)，其正则化线性目标正是本文使用的目标加权迹。本文将该准则用于固定源数据池的并集，并保留多个并集供带标签验证选择。分布匹配采用另一种思路。MMD 比较源分布与目标分布的均值嵌入 (Gretton et al., 2012)；采用齐次二次核时，这一比较由二阶矩决定。矩对齐也被用于多源域适应中的表示学习 (Peng et al., 2019)。本文固定编码器，在同一批候选组合上比较不确定性降低与矩匹配两类评分。

2.2 计算预算下的数据选择

受计算预算约束的数据选择需要同时考虑选择过程和后续训练的开销 (Yin & Rush, 2025)。数据池预筛选在其中引入一个中间决策：应当让多少组合进入监督评价？较宽的短名单可能保留好候选，却仍需要较多拟合和验证。本文同时比较候选保留与最终所选模型，再分别测量决策时间和特征准备成本，从而区分评价次数减少与决策加快。

2.3 表示几何与多样性

RankMe 利用有效秩在无需下游标签的条件下评估已学习的表示 (Garrido et al., 2023)。行列式点过程偏好方向互补的子集 (Kulesza & Taskar, 2012)。两者都为训练任务模型之前比较源数据池提供了思路。不过，几何目标与保留低目标损失候选并不相同：某些变化可能对具体任务没有帮助，而任务重要方向可能仅占表示空间的一部分。本文将合并有效秩和明确指定的子空间 DPP 实现作为目标无关对照。

3 基于几何的数据池预筛选

3.1 问题与两阶段流程

数据池是固定样本块，候选是若干块的可行并集。研究使用一个候选族，以及分别用于筛选、验证和测试的目标数据。预筛选与监督评价最终输出一个所选预测器。短名单包含候选组合，而不是单张图像。

设 $H_i \in \mathbb{R}^{n_i \times d}$ 为数据池 i 的特征，使用固定编码器和共享、标签无关的预处理。Gram 矩阵 $G_i = H_i^\top H_i$ 记录特征方向的强度及其关系。对候选族 $\mathcal{C}$ 中的 S ，有 $G_S = \sum_{i \in S} G_i$ 、 $n_S = \sum_{i \in S} n_i$ 。无标签目标选择特征估计非中心化二阶矩 $C_T = \mathbb{E}_T[hh^\top]$ ，描述目标的方向能量。

预筛选对 $\mathcal{C}$ 排序，将前 s 个组合保留为 $\mathcal{Q}_s$ 。随后使用各组合的源标签训练预测器，再通过独立目标验证集选出 $\hat{S} \in \mathcal{Q}_s$ 。目标测试数据用于评价已冻结的选择和保留的候选。预筛选阶段记作 U0，只读取源特征和目标选择特征，不读取标签或验证、测试数据。监督阶段记作 U2，读取源标签和目标验证数据。目标无关规则仅使用源信息。这样的划分使预筛选能够利用可复用特征，同时把针对具体任务的证据留给最终选择。

各组合使用同一分类器和验证过程；预筛选改变的是哪些组合得到评价，而不是编码器。等样本成本研究固定训练样本数，并不固定运行时间。

3.2 共享几何与谱多样性

奇异值分解 $H = U\Sigma V^\top$ 将特征方向与其强度分开。对于固定非负权重 w_i ，堆叠缩放后的源矩阵得到

$$G_S = H_S^\top H_S = \sum_{i \in S} w_i G_i. \quad (1)$$

该矩阵和的特征值是合并特征奇异值的平方。只要预处理坐标保持固定，它就保留了方向强度及其跨数据池的对应关系。实验中权重均为一。

有效秩将奇异值归一化为概率向量，再对其熵取指数 (Roy & Vetterli, 2007):

$$r_{\text{eff}}(H) = \exp\left(-\sum_j p_j \log p_j\right), \quad p_j = \frac{\sigma_j(H)}{\sum_k \sigma_k(H)}. \quad (2)$$

对于非零矩阵，约定 $0 \log 0 = 0$ ，且 $1 \leq r_{\text{eff}}(H) \leq \text{rank}(H)$ ；正奇异值相等时取得上端点。两个奇异值之比为 9:1 时，有效秩约为 1.38，两者相等时则为二。计算时先对 Gram 特征值取平方根，再归一化；直接归一化特征值会定义另一个评分。重复整个矩阵不改变有效秩，因此它衡量谱形状，而不是样本证据数量。有效秩是目标无关对照，而不是目标感知评分所需的中间步骤。

仅凭边际谱和主角度，甚至不一定能够确定这一合并统计量：相同强度可能被分配给不同的共享或非共享方向。附录 A 给出显式反例及局部谱公式成立的条件。本文评分保留 Gram 算子，使这些方向信息仍然可用。

3.3 目标加权与矩匹配

目标加权关心哪个源组合能够在目标需要覆盖的方向上降低不确定性。共享线性模型使这个问题得到精确定义。考虑标量贝叶斯回归： $\theta \sim N(0, P_0)$ 、 $P_0 \succ 0$ ，且 $y = h^\top \theta + \epsilon$ ，独立噪声满足 $\epsilon \sim N(0, \sigma^2)$ 、 $\sigma^2 > 0$ 。源与目标共享 θ 和噪声模型，目标协变量不再提供关于 θ 的额外信息。给定源设计矩阵，后验协方差与后验均值的目标预测风险为

$$P_S = (P_0^{-1} + \sigma^{-2} G_S)^{-1}, \quad R_T(S) = \sigma^2 + \text{tr}(C_T P_S). \quad (3)$$

这里的期望同时平均后验不确定性与新目标观测，推导见附录 A。

式 (3) 引出评分 $f_A(S) = \text{tr}(\hat{C}_T P_S)$ ，在固定超参数下取其最小值。各向同性先验下，它就是 transductive experimental design 的正则化目标预测方差准则 (Yu et al., 2006)；为与已记录实验一致，本文保留 Target A-opt 这一名称。源观测降低其所覆盖方向上的不确定性，目标二阶矩则按预测时这些方向的出现程度赋予权重。因此，即使一个数据池的总体多样性不高，只要它覆盖了尚不确定且对目标重要的方向，也可能具有价值。增加半正定源 Gram 不会使该分数增大。

实验采用 $P_0^{-1} = I$ 和 $\sigma^2 = 1$ 。将 G_S 写为 $U \text{diag}(\lambda_j) U^\top$ ，并包含零特征值对应的方向，可得

$$f_A(S) = \sum_j \frac{u_j^\top \hat{C}_T u_j}{1 + \lambda_j}. \quad (4)$$

分母反映源数据对方向 u_j 的覆盖，分子衡量该方向对目标的重要性。因此，即使两个组合的特征值相同，只要其方向与目标的对齐方式不同，也可以得到不同分数。有效秩对相同谱一视同仁，目标加权则区分这些覆盖在哪里有用。

二阶矩匹配提出另一个问题：源数据的平均方向能量与目标有多接近？它最小化

$$f_M(S) = \left\| G_S / n_S - \hat{C}_T \right\|_F^2. \quad (5)$$

它对应核 $k(h, h') = (h^\top h')^2$ 下包含对角项的经验 MMD 平方。它直接使源数据的平均方向能量接近目标，而不是对后验不确定性矩阵加权。两种准则读取相同特征，因此二者比较检验的是：相对直接矩匹配，逆协方差加权能否提供额外价值。

共享条件模型是 A-opt 风险解释的依据，这一假设有实际含义。例如，所有特征均为 1，两个源数据池的标签分别恒为 +1 和 -1；当两个目标世界的常数标签相反时，源预测器的风险排序随之反转，而特征几何完全不变。因此，在分类实验中，我们使用训练后的 ridge-softmax 和逻辑回归读出器评价这些分数，而不将式 (3) 直接视为分类损失。

3.4 区分候选保留与最终选择

最终选择有两种损失来源：预筛选丢掉好候选，或者验证从保留集合中选了较差的成员。设 $\ell(S)$ 为固定已训练预测器的目标风险， $v(S)$ 为验证损失。若全部 $S \in \mathcal{Q}_s$ 满足 $|v(S) - \ell(S)| \leq \epsilon$ ，则验证最优选择满足

$$\ell(\hat{S}) - \min_{S \in \mathcal{C}} \ell(S) \leq \underbrace{\min_{S \in \mathcal{Q}_s} \ell(S) - \min_{S \in \mathcal{C}} \ell(S)}_{\text{短名单遗漏}} + 2\epsilon. \quad (6)$$

附录 A 证明这一界。第一项衡量排除最佳候选带来的损失，第二项约束短名单内的验证误差。本文审计有限测试集上的对应量和前十名保留情况。偏差条件用于解释这两类误差来源，实验没有将其估计为总体风险保证。

3.5 决策预算与成本核算

全搜索参照训练全部候选，并选择 $S_{\text{full}} = \arg \min_{S \in \mathcal{C}} v(S)$ ，这是可以部署的过程。测试 oracle 则是观测测试损失最低的候选，仅用于审计。记测试 Brier 为 $b(S)$ ，即预测类别概率与独热标签之间的平均平方距离，越低越好。本文报告 $b(\hat{S}_s) - b(S_{\text{full}})$ ，以及超过指定绝对容忍值的重复任务比例。由于验证与测试排序可能不同，这个差值可以为负。

已有冻结特征时，预筛选成本由排序工作及保留候选的拟合、验证组成。从原始图像开始时，还需要编码器初始化和特征提取；目标感知评分额外需要目标选择特征。这是两种不同的核算情形。预筛选值得使用的成本条件，是将额外特征工作计入后，筛选开销仍小于它替代的监督评价。候选数只衡量该条件的一部分，并不是实际时间。尤其对岭回归，同一类矩阵操作既用于方便地计算线性评分，也可能占模型拟合成本的相当部分。

4 评价协议

受控合成任务检验风险模型。随后在 PACS 和 Office-Home 上，以预先指定的实质效应门槛评价直接选择 (Li et al., 2017; Venkateswara et al., 2017)，并在这些结果之后开展穷举改善空间分析。后续 DomainNet 研究固定样本成本、评价短名单，其配置在特征提取和结果评价前冻结。测试样本重采样及之后的投影、读出器实验属于探索性补充分析。附录 B 记录配置和结果位置。

我们从官方 cleaned DomainNet 数据中 (Peng et al., 2019) 按固定哈希规则选择 100 个类名。六个域各自提供互不重叠的 1,536 张目标选择图像、1,024 张目标验证图像和 3,072 张锚点池图像，均取自官方训练集，另有 2,048 张官方测试图像。manifest 共含 46,080 张图像。类别元数据用于定义基准词表，但不向预筛选开放。

CLIP ViT-B/32 (Radford et al., 2021) 作为冻结的构造锚点。各域内部按其第一主成分分数划分低、中、高三个层次，每层提供一个包含 512 张图像的块。对给定目标，排除其自身数据块，从剩余块中穷举 $\binom{15}{3} = 455$ 个组合，每个包含 1,536 张源图像。ResNet-50 和 DINOv2-B/14 提供评价特征 (He et al., 2016; Oquab et al., 2024)。全部规则共享行归一化、固定的 128 维 Rademacher 投影及投影后行归一化。固定样本数量消除了候选训练成本差异的一个直接来源。

Target A-opt 使用 $P_0^{-1} = I$ 和 $\sigma^2 = 1$ 。对照包括二阶矩 MMD、目标能量 $\text{tr}(\hat{C}_T G_S / n_S)$ 、Bayesian D-opt、合并有效秩、子空间 DPP、域平衡以及 20 个固定种子的随机排序。所有规则评价相同候选族。域平衡额外读取源域标识。核定义和并列规则见附录 B。

预筛选生成大小为 10, 25, 50, 100, 227 的嵌套短名单，以 227 为主设置。原协议的 U2 阶段独立评价每种方法的主短名单，采用正则化为 1、无截距、固定 softmax 温度的岭回归。验证 Brier 最小的组合为最终选择，平局按字典序处理。较小短名单复用同方法的嵌套评价，不共享跨方法缓存。测试阶段先核验上游哈希，再评价全部组合，建立穷举审计参照。

补实验新增四个投影种子和固定正则化的多项逻辑回归，保持候选成员与数据角色不变。筛选、验证和测试仍由独立进程执行，但不同方法复用同一组合的拟合模型来审计各自短名单。因此，该运行时间反映的是缓存研究审计的成本，而非各方法分别部署的成本。读出设置和来源核验见附录 B。

我们衡量有多少测试前十名候选通过筛选，以及验证选择与测试 oracle S^* 的差距。召回率衡量候选保留，而不是分类准确率；遗憾衡量相对 oracle 的损失差距：

$$\text{Recall}_{10}(Q_s) = \frac{|Q_s \cap \text{Top}_{10}(b)|}{10}, \quad \text{Regret}(\hat{S}) = \frac{b(\hat{S}) - b(S^*)}{|b(S^*)|}. \quad (7)$$

原主判据要求至少移除 50% 的组合、平均召回率至少 90%、平均归一化遗憾至多 5%。Brier 为主指标。补充的负对数似然 (NLL) 和分类错误率审计分别使用对应验证指标选择候选，并在访问测试数据之前固定指标。




图 1: 图中给出最终测试 Brier 与穷举验证选择之差随候选评价数的变化, 两面板纵轴尺度不同。零线对应验证集选出的模型, 而不是测试 oracle。曲线是四个新投影种子的事后汇总; 横轴为拟合次数, 不是实测时间。

首先在每个数据集-目标域内平均编码器, 在任务内平均随机排序。PACS/Office-Home 共八个这样的单位, DomainNet 共六个。补实验种子同样在域内平均。原 bootstrap 区间对目标单位重采样; 测试样本分析则固定训练模型, 在各目标内部重采样图像。种子、编码器和重叠组合是重复测量, 而不是新增的独立数据集。

5 实验结果

本节先考察 DomainNet 上的最终选择与计算成本, 再比较域组成和域内数据块的作用。候选保留与读出器分析说明哪些备选仍然可用。此前的共享模型和直接选择研究用于帮助解释这些结果, 并非新增的等成本复现。

5.1 不同评价预算下的最终选择

图 1 对四个新投影种子进行重分析, 将关注点从前十名成员转向最终测试损失。参照方法拟合全部候选, 再按相同验证指标选择。在较小预算下, 目标感知名单的平均 Brier 低于同等规模的随机名单; 其曲线在评价全部候选之前就已接近穷举验证参照。因此, 实际比较应当是在指定损失容忍值下比较决策流程, 而不仅是比较排序相关性。

对于逻辑回归, 评价 50 个 A-opt 或 MMD 候选的平均 Brier 低于评价 227 个随机候选。两项比较在六个域均值中的五个上有利于几何筛选。A-opt 和 MMD 的配对均值差分别为 -0.001518 、 -0.001664 ; 描述性域 bootstrap 范围分别为 $[-0.003517, 0.000023]$ 、 $[-0.003720, -0.000119]$ 。各域共享源池, 因此这些范围不能作为独立数据集上的置信声明。

任务级超差比例补充了均值没有说明的信息。在规模 50 处, 两种几何方法各有 48 个编码器-种子-域重复任务中的一个, 相对穷举验证的绝对 Brier 差超过 0.005, 即 2.08%。随机筛选 227 个候选时, 按规定平均后的超差比例为 15.52%。附录表 5 给出最终损失。这一容忍值是探索性敏感性网格中的一点, 不是新的成功门槛。比较同时描述了平均质量, 以及已评价任务中出现较大差距的频率。

5.2 实测决策与特征成本

表 1 检验评价较少候选是否节省时间。各方法独立评分、拟合和验证, 不跨方法共享已拟合模型, 质量与时间来自同一批运行。与前述四种种子分析不同, 计时固定一个投影, 每个编码器-目标-读出器任务执行三次。全部实测预算见附录图 4。

投影特征已在内存时, 规模 50 的 A-opt 与 MMD 用时约为穷举逻辑回归的十分之一。加入实测图像特征工作后, 二者的核算成本仍约为穷举验证的 56%。但对岭回归, 额外目标选择特征的成本超过了筛选省去的廉价拟合。因此, 相同的候选数量削减, 对两种读出器产生不

同后果。图像总成本由独立测量分项相加，不含数据池构造、下载、缓存写盘和测试审计。磁盘缓存加载与投影另见附录表 7。

表 1: 表中给出两种读出的配对最终 Brier 与平均核算时间，单位为秒。Resident 从内存中的投影特征开始，包含评分、拟合和验证。Images 在此基础上加入固定池清单的独立特征测量，是分项加总而非完整流水线重放。全部均值来自同一批计时选择。

	Readout	Screen	Fits	Brier	Resident (s)	Images (s)
	Ridge	A-opt	50	0.986655	0.53	39.59
	Ridge	MMD	50	0.986643	0.21	39.27
	Ridge	Random	227	0.986653	0.75	35.30
	Ridge	Full validation	455	0.986639	1.48	36.03
	Logistic	A-opt	50	0.863170	4.49	43.54
	Logistic	MMD	50	0.863110	4.31	43.37
	Logistic	Random	227	0.864241	21.23	55.77
	Logistic	Full validation	455	0.862992	42.83	77.38

5.3 候选构造与源域控制

随后固定投影和读出参数，将 CLIP 分层块替换为相同源图像上的哈希分块，构造过程不使用标签或特征。均值匹配和域级矩匹配作为更简单的对照。后者先合并同一源域的全部块，再评价域混合，因此无法区分源域组成不同的不同块。附录表 6 报告这项探索性挑战；随机平局处理与冻结协议中的字典序处理单独报告。

新构造保留了相对于随机筛选的整体 Brier 优势，但改变了哪些几何细节更有帮助。在规模 50 处，重分块后的域级匹配与 MMD 获得相近的平均最终 Brier。因此，在这一设置中，使用域级矩而不区分域内具体数据块，也能形成表现良好的全局短名单。均值匹配在原块上具有竞争力，重分块后则较弱。

为固定域组成后比较数据块，我们将从各源域取块数量相同的候选放入一组，在每个非单例组保留向下取整的一半候选。在原分块与逻辑回归下，A-opt 和 MMD 分别在约 77%、76% 的组中保留经验 Brier 最优候选，随机选择约为 45%。重新分块后，两者降至约 56%、55%；按分类错误率评价时，二者均低于随机。这些数值是组内最优候选保留率，而不是全局前十名召回。它们表明原构造中存在有用的块信息，但收益依赖构造和指标。

5.4 保留有希望的等成本组合

原 DomainNet 研究考察哪些候选通过预筛选后仍然可用（表 2）。A-opt 在移除约一半组合的同时，保留了几乎全部测试前十名候选。A-opt 和 MMD 的所有主设置短名单都包含测试 Brier oracle；它们剩余的选择遗憾来自验证阶段选取了其他成员。这体现了式 (6) 的区分：保留最佳候选与选中它是两种不同结果。

MMD 与 A-opt 的主设置召回率和选择遗憾相同，并在每个编码器-目标任务中经验验证阶段选出同一最终组合。在更小短名单上，MMD 的平均召回率更高（附录图 2）。因此，A-opt 更高的完整排序相关性，并没有转化为这些工作点上更好的候选保留。两者相对已测目标无关规则的共同优势，支持使用目标条件二阶信息；直接矩匹配在这里已经有效。

5.5 投影与读出器敏感性

原 ridge-softmax 的候选损失差异很小：每个候选都处在 5% 遗憾门槛内，因此该门槛不能区分预筛选方法。探索性补实验考察四个新投影和逻辑回归下是否仍有高召回，保持源成员和样本成本固定。附录表 3 报告新种子均值，原种子作为实现对照。

A-opt 在两种读出器下的 Brier 前十名平均召回均为 98.33%，MMD 略高。平均相对 Brier 最好到最坏跨度从 ridge-softmax 的 0.248% 增至逻辑回归的 14.65%。这表明，高召回在候选差异更明显时仍然存在，并不只出现在 Brier 损失几乎相等的设置中。两种目标感知评分也平均保留了大部分按 NLL 和错误率排序的优质候选，MMD 在这些比较中同样较高。

表 2: 原 DomainNet 实验从 455 个组合中保留 $s = 227$ 个。均值先在六个目标域内平均编码器。召回率对应测试 Brier 前十名; 遗憾相对于 oracle Brier; Spearman 衡量完整筛选排序与测试损失排序的一致性。

Screen	Recall (%)	Regret (%)	Spearman
Target A-opt	98.333	0.001311	0.7443
Second-moment MMD	98.333	0.001311	0.6902
Bayesian D-opt	82.500	0.002658	0.4996
Merged effective rank	81.667	0.002909	0.4951
Random (20 repeats)	48.958	0.003899	0.0016
Target energy	46.667	0.009347	-0.0399
DPP subspace	27.500	0.009067	-0.0633
Domain balance	25.000	0.012083	0.0681

在主短名单规模下, 两种方法在所有新种子任务中都保留了 Brier 测试 oracle, 平均选择遗憾也相同。具体指标的结果存在差异: 一个 A-opt 任务按错误率排序的召回仅为 40%, 而验证阶段未选中已保留的测试错误率 oracle。任务细节和完整对照表见附录 C。

5.6 共享风险模型下的目标加权

此前的合成研究检验风险模型成立时的目标加权。它改变特征维度、候选数量、源预算、目标样本数及目标秩, 对 216 个设计设置分别使用 20 个生成种子。在共享条件模型下, A-opt 相对最强目标无关有效秩对照降低模型风险 4.23%, 相对 MMD 降低 14.85%。对应的描述性 95% 区间为 $[3.86, 4.62]\%$ 与 $[13.99, 15.70]\%$, 先平均种子, 再对设计设置重采样。这些比较针对模型中的线性风险, 而非前述分类损失。

另一组源条件偏移实验改变回归机制, 其平均归一化预测遗憾从无偏移时的 0.211 增至最大测试偏移下的 3.143。这一终点评价实际预测, 而非后验风险。两组研究分别考察了覆盖目标相关方向的收益, 以及跨不同条件机制迁移标签的影响。

5.7 直接选择与可用改善空间

PACS 和 Office-Home 实验考察评分能否直接选出更好的源组合。在块预算 $K = 3$ 时, A-opt 相对 DPP 和 MMD 的单位内相对 Brier 改善均值分别为 0.351% 和 0.273%, 均未达到预设的 2% 实质效应门槛。配对差值区间相对 DPP 跨越零, 相对 MMD 则为负; 完整数值见附录 C。这些比较固定块数, 而非源样本数。

事后审计评价全部可行组合, 以测量改善空间: 相对参照, 选择测试最优候选能够减少多少损失。附录图 3 显示, 相对 DPP 的平均改善空间只有 0.781%。大多数目标单位留给选择器的平均损失改善空间有限。这也区分了直接预测收益与预筛选问题: 能否在减少组合评价的同时留下有用选择。

6 讨论

6.1 何时值得预筛选?

实验通过三个相互关联的结果评价预筛选: 哪些候选被保留、验证选中了哪个预测器, 以及决策需要多少工作。高召回本身只回答第一个问题。MMD 与域级匹配的结果也说明, 评价更精细的块级几何时, 简单的目标比较是必要基线。

工作点应当依据目标指标、可接受损失差距和实测成本, 而非仅看保留率。压缩又增加了一项要求: 评分仍须区分候选。附录 C 中, 有效草图区间仍然过宽, 无法在有用的字节预算下确定选择。

6.2 局限性

等样本成本证据来自相同 DomainNet 图像上的两种构造。目标域之间共享源数据池, 新增种子与读出器也复用相同图像。它们衡量的是基准内部敏感性, 而非独立数据上的复现。相对

PACS/Office-Home，数据集、投影、样本预算和候选构造均有变化，因此不能单独识别候选异质性的因果作用。

贝叶斯推导针对共享线性回归，分类结果则从经验上评价其评分的作用。测试样本重采样以拟合模型和验证选择为条件，不衡量训练或验证选择带来的不确定性。绝对任务质量也取决于候选族，补充适配器实验提供了例子。图像成本来自实测分项，不是完整部署流程的重放：未计入候选构造与缓存写盘，特征测量也仅在一套硬件上执行一遍。独立等成本数据集、受控验证预算，以及与编码器预训练数据的重叠检查仍然重要。

7 结论

本文评价了目标感知几何在监督数据池选择之前的预筛选作用。分析将实验设计与共享线性风险联系起来，并区分候选遗漏和验证误差。在固定样本成本的 DomainNet 组合上，评价 50 个 A-opt 或 MMD 候选的平均测试 Brier 低于评价 227 个随机候选。域级对照表明块信息有用但依赖构造，MMD 在 DomainNet 预筛选比较中具有竞争力。独立计时支持已有特征缓存时的计算节省；加入实测特征成本后，逻辑回归仍有节省，岭回归则发生反转。这些证据支持同时依据最终选择、可接受的损失差距和实测成本评价预筛选。

AI 使用声明

生成式 AI 工具参与了概念重构、数学命题与证明草拟、实验设计、软件实现、结果解释、文献检索、论文写作、绘图脚本编写及中文翻译。本稿数值发现来自已记录的实验产物，而非生成的观测值。AI 辅助不构成对实验产物或数学主张的独立验证。提交版本的最终核验与责任仍由人类作者承担。

可复现性声明

附录 A 给出证明细节；第 4 节和附录 B 给出预处理、访问规则、候选构造、指标与结果路径。代码仓库为 <https://anonymous.4open.science/r/collapsemodel-1DB6>。结果表和 manifest 支持汇总复现；大型特征缓存通过哈希标识，不重复存入 Git。我们不声称不同硬件能够逐位复现全部特征。

伦理声明

研究使用既有基准图像及预训练编码器，不新增参与者招募。公开可用并不消除图像许可、隐私或表示偏差问题。我们不声称多样的特征谱或高短名单召回率意味着所选数据池在社会层面具有代表性、公平性或隐私保护。候选类别体系、预训练重叠不确定性及视觉分类限制了下游部署主张。数据集和模型访问仍须遵守其原有条款。

参考文献

- Koenraad M. R. Audenaert. A sharp continuity estimate for the von Neumann entropy. *Journal of Physics A: Mathematical and Theoretical*, 40(28):8127–8136, 2007. doi: 10.1088/1751-8113/40/28/S18.
- Xavier Fontaine, Pierre Perrault, Michal Valko, and Vianney Perchet. Online A-optimal design and active linear regression. In *International Conference on Machine Learning*, pp. 3374–3383, 2021. URL <https://dblp.org/rec/conf/icml/FontainePVP21>.
- Quentin Garrido, Randall Balestriero, Laurent Najman, and Yann LeCun. RankMe: Assessing the downstream performance of pretrained self-supervised representations by their rank. In *International Conference on Machine Learning*, pp. 10929–10974, 2023. URL <https://dblp.org/rec/conf/icml/GarridoBNL23>.
- Arthur Gretton, Karsten M. Borgwardt, Malte J. Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *Journal of Machine Learning Research*, 13(25):723–773, 2012. URL <https://dblp.org/rec/journals/jmlr/GrettonBRSS12>.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016. URL <https://dblp.org/rec/conf/cvpr/HeZRS16>.
- Alex Kulesza and Ben Taskar. Determinantal point processes for machine learning. *Foundations and Trends in Machine Learning*, 5(2–3):123–286, 2012. doi: 10.1561/22000000044. URL <https://dblp.org/rec/journals/ftml/KuleszaT12>.
- Da Li, Yongxin Yang, Yi-Zhe Song, and Timothy Hospedales. Deeper, broader and artier domain generalization. In *IEEE International Conference on Computer Vision*, 2017. URL <https://dblp.org/rec/conf/iccv/LiYSH17>.
- Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. URL <https://dblp.org/rec/journals/tmlr/OquabDMVSKFHMEA24>.

- Xingchao Peng, Qinxun Bai, Xide Xia, Zijun Huang, Kate Saenko, and Bo Wang. Moment matching for multi-source domain adaptation. In *IEEE/CVF International Conference on Computer Vision*, pp. 1406–1415, 2019. URL <https://dblp.org/rec/conf/iccv/PengBXHSW19>.
- Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pp. 8748–8763, 2021. URL <https://dblp.org/rec/conf/icml/RadfordKHRGASAM21>.
- Olivier Roy and Martin Vetterli. The effective rank: A measure of effective dimensionality. In *15th European Signal Processing Conference*, pp. 606–610, 2007. URL <https://dblp.org/rec/conf/eusipco/RoyV07>.
- Hemanth Venkateswara, Jose Eusebio, Shayok Chakraborty, and Sethuraman Panchanathan. Deep hashing network for unsupervised domain adaptation. In *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 5018–5027, 2017. URL <https://dblp.org/rec/conf/cvpr/VenkateswaraECP17>.
- Junjie Oscar Yin and Alexander Rush. Compute-constrained data selection. In *International Conference on Learning Representations*, 2025. URL <https://dblp.org/rec/conf/iclr/YinR25>.
- Kai Yu, Jinbo Bi, and Volker Tresp. Active learning via transductive experimental design. In *Proceedings of the 23rd International Conference on Machine Learning*, pp. 1081–1088, 2006. doi: 10.1145/1143844.1143980. URL <https://dblp.org/rec/conf/icml/YuBT06>.

A 证明与数学主张的适用范围

命题 1 (方向分配影响合并结果). 存在行归一化的矩阵对 (A, B_1) 与 (A, B_2) , 它们具有相同的边际奇异值谱和行空间主角度, 但拼接后的有效秩不同。

证明. 令 A 包含四行 $e_1^\top$ 和一行 $e_2^\top$; B_1 包含四行 $e_1^\top$ 和一行 $e_3^\top$; B_2 包含一行 $e_1^\top$ 和四行 $e_3^\top$. 三者非零奇异值谱均为 $(2, 1)$, 两组行空间主角度均为 $(0, \pi/2)$. 合并 Gram 谱分别为 $(8, 1, 1)$ 与 $(5, 4, 1)$, 有效秩约为 2.6260 与 2.8495. 尽管边际摘要相同, 共享方向得到的能量却不同. $\square$

设 u, v 为单位方向, $u^\top v = c \in [0, 1]$. 在正交基 u, z 中写成 $v = cu + \sqrt{1-c^2}z$, 算子 $a^2uu^\top + b^2vv^\top$ 表示为

$$\begin{pmatrix} a^2 + b^2c^2 & b^2c\sqrt{1-c^2} \\ b^2c\sqrt{1-c^2} & b^2(1-c^2) \end{pmatrix}. \quad (8)$$

其迹为 $a^2 + b^2$, 行列式为 $a^2b^2(1-c^2)$, 因此特征值为

$$\lambda_{\pm} = \frac{a^2 + b^2 \pm \sqrt{(a^2 - b^2)^2 + 4a^2b^2c^2}}{2}. \quad (9)$$

当 $c = 1$ 时, 第二分支为零. 若相关子块相互正交, 且对两个源 Gram 都是不变子空间, 汇集这些特征值对便得到完整谱; 未配对方向贡献自身特征值. 这一相容条件不可省略, 因为主向量不必是奇异向量。

固定 H_S 并采用高斯似然, 对先验与似然乘积完成平方可得后验精度 $P_0^{-1} + \sigma^{-2}H_S^\top H_S$ 和均值 $\mu_S = P_S\sigma^{-2}H_S^\top y_S$. 对独立目标观测 $y = h^\top\theta + \epsilon$, 给定训练数据与 h , 有

$$\mathbb{E}[(y - h^\top\mu_S)^2 \mid H_S, y_S, h] = \sigma^2 + h^\top P_S h. \quad (10)$$

对 h 积分得到式 (3). 这里假设目标协变量分布不会在该模型之外额外透露关于 θ 的信息. 若源数据具有不同回归函数, 或标签为多分类且采用 softmax 读出, 则该推导不再等于所评价的损失. 证明不约束这种模型误差. 以有限样本估计替代 C_T 还引入另一类偏差, 恒等式也不会自动消除它。

若 $G \succeq \tilde{G} \succeq 0$, 逆矩阵序给出 $(P_0^{-1} + \sigma^{-2}G)^{-1} \preceq (P_0^{-1} + \sigma^{-2}\tilde{G})^{-1}$. 与 PSD 目标矩相乘取迹保持该顺序. 更一般地, 若遗漏草图尾部之和满足 $0 \preceq G - \tilde{G} \preceq \delta I$, 定义 $B = P_0^{-1} + \sigma^{-2}\tilde{G}$, 则

$$\text{tr}(\hat{C}_T(B + \sigma^{-2}\delta I)^{-1}) \leq f_A(G) \leq \text{tr}(\hat{C}_TB^{-1}). \quad (11)$$

各 PSD 尾部的有效谱范数上界之和, 是一种可取的 δ . 当某候选上界低于所有竞争者下界时, 可以认证该候选的代理排序. 因此, 除了覆盖率, 区间宽度也决定草图能否支撑下一次选择. 归档扫描使用其文档中的字节计数, 评价这类代理比较。

令 S_Q 在 Q_s 中最小化 ℓ . 短名单上的一致偏差给出

$$\ell(\hat{S}) \leq v(\hat{S}) + \varepsilon \leq v(S_Q) + \varepsilon \leq \ell(S_Q) + 2\varepsilon. \quad (12)$$

减去 $\min_{S \in \mathcal{C}} \ell(S)$ 即得式 (6). 该代数推导没有给出概率声明. 若要获得总体泛化保证, 必须结合真实依赖与选择流程另外证明偏差事件. 有限测试集上的穷举分数本身不足以提供这种证明。

映射 $\phi(h) = hh^\top$ 采用 Frobenius 内积, 满足 $\langle \phi(h), \phi(h') \rangle_F = (h^\top h')^2$. 源与目标经验特征均值之间的平方距离即式 (5). 这是有偏经验平方 MMD, 即 V 统计量, 而非去掉对角项的无偏估计. 它依赖非中心化二阶矩, 无法区分所有具有相同二阶矩的分布. 我们将其作为计算简单的同信息对照, 而非完备分布差异度量。

B 实现与审计细节

原 DomainNet 实验拟合岭回归读出, 并将其分数转换为类别概率. 权重与 Brier 损失为

$$W_S = (I + G_S)^{-1} \sum_{i \in S} H_i^\top Y_i, \quad p(x) = \text{softmax}(h(x)^\top W_S),$$

$$b(S) = \frac{1}{n_T} \sum_t \|p(x_t) - e_{y_t}\|_2^2. \quad (13)$$

Y_i 为固定 100 类词表下的源 one-hot 标签矩阵。不使用截距或温度调参。载入 float32 特征后，线性代数以 float64 计算。通过 Gram 特征分解计算有效秩时，先将负舍入特征值裁剪为零，再取平方根得到奇异值，仅保留 $\sigma_j > \sigma_{\max} \sqrt{8\epsilon_{64} \max(n_S, d, 1)}$ 。代码对零矩阵返回零秩。该阈值针对数值秩，不改变熵定义。共享投影种子为 20260911，维度为 128；冻结 DomainNet 协议内部没有根据结果选择维度。

Bayesian D-opt 最大化 $\log \det(I + G_S)$ 。子空间 DPP 取每个块的前 16 个 Gram 特征向量 U_i ，定义 $K_{ij} = \|U_i^\top U_j\|_F^2 / 16$ 、 $K_{ii} = 1$ ，将其数值投影到 PSD 相关矩阵，再最大化 $\log \det(K_{S,S} + 10^{-8}I)$ 。该核描述块子空间，而非单图像特征。域平衡最大化已覆盖域数量，减去各域块数平方和的 10^{-3} 倍。确定性分数按组合标识字典序处理并列。这些是固定对照；该 DPP 构造表现不佳，不是对所有行列式选择方法的结论。

DomainNet 记录图像内容哈希、样本标识、官方划分、角色及类别词表。特征提取前验证归档与划分校验和。角色互斥和重复内容检查处理已物化基准内部的重叠，但不能排除语义近重复或预训练污染。全部筛选方法使用相同源块、投影、目标选择行和候选集合。特征提取忽略标签，基准物化则使用类别元数据，并为后续授权阶段存储标签。

筛选、验证与审计 manifest 绑定配置和上游产物哈希，分阶段加载器执行标签与划分权限。原协议的验证阶段单独评价每种方法或随机重复。选择冻结后，测试审计覆盖每个编码器的全部 6×455 个组合，穷举 oracle 作为研究参照。补实验的缓存策略如下。

CUDA 重建保留原样本标识、候选成员、预处理和超参数，全部十二个 Brier 前十名集合与原实验一致。逐样本损失均值与重建聚合审计的误差不超过 1.78×10^{-15} 。每个目标域对其 2,048 个测试样本执行 2,000 次配对 bootstrap，全部组合、编码器和四种损失共享权重。拟合模型与验证选择固定，平局按组合标识处理。这些重采样衡量对测试样本抽取的敏感性。原 Brier 前十名与 NLL、原始平方损失及分类错误率前十名的平均重叠分别为 90.83%、30.83% 和 29.17%。

种子 20260917、20260918、20260919、20260920 生成新的 128 维 Rademacher 投影，保持投影前后行归一化。种子 20260911 用作实现对照，不计入新种子均值。逻辑回归采用 L2 正则化、 $C = 1$ 、无截距、LBFGS，容差为 10^{-6} ，最多迭代 1,000 次。若出现收敛警告则终止任务；实际没有出现警告，最大迭代次数为 24。类别词表固定，源数据中缺失类别的概率设为零。

所有方法保留原筛选规则、候选组合和五种短名单规模，由独立进程依次筛选、拟合验证、测试冻结模型。测试特征读取前，核验源码、配置、来源、模型及选择的哈希。每个读出器对全部组合拟合一次，各方法复用这些拟合结果。这种缓存穷举评价用于比较不同短名单的反事实结果。Brier、NLL 和错误率分别使用自己的验证损失作最终选择。原种子岭回归在 5,460 个重建测试组合上的最大损失差异为 1.78×10^{-15} ，全部 1,620 个 Brier 验证选择完全一致。

两个编码器、五个种子、两种读出器合计完成 54,600 次拟合。新种子汇总先在任务内平均随机重复，再在目标域内平均编码器和种子，最后平均六个域。每个读出器包含 48 个编码器-种子-目标域重复测量，但仍是共享相同源池的六个目标域单位。

归档保留历史实验编号用于定位结果，不应将其与论文科学问题混淆。以下路径相对于匿名代码仓库：

- 共享模型与偏移研究 (E1): results/target_conditioned/e1_synthetic/expanded_v3_controlled_rng/。
- PACS/Office-Home 对照 (E2): results/target_conditioned/e2_dataset_selection/method_v1/。
- 事后改善空间 (E2a): results/target_conditioned/e2_dataset_selection/oracle_headroom_v1/。
- 等成本短名单 (E2b): results/target_conditioned/e2b_fixed_cost_shortlist/domainnet_v1/。
- 风险草图扫描 (E5): results/target_conditioned/e5_sketch_certificate/expanded_v3_controlled_rng/。
- 重建与测试重采样 (R1/R2): results/target_conditioned/revision_20260916/。




图 2: 图中展示原 DomainNet 实验的测试 Brier 前十名平均召回率如何随短名单规模变化。虚线为预设召回门槛。全部曲线使用相同候选组合, 各规则按其对应权限读取特征。

- 投影与读出器补实验 (R3/R4): results/target_conditioned/revision_20260917/。

DomainNet 数据 manifest 前缀为 1ba25059df70be4d, 候选集 ID 前缀为 545fe86c8c9e8304, 汇总 ID 前缀为 2d473cb9eb977e85; 完整 SHA-256 位于产物中。原配置为 code/configs/target_conditioned_e2b/domainnet_v1.json, 实现为 scripts/run_target_conditioned_e2b_shortlist.py。补实验采用 code/configs/target_conditioned_e2b/readout_projection_v1.json 和 scripts/run_e2b_readout_projection.py, 汇总表位于 R3/R4 目录内的 revision_results/e2b_readout_projection_v1/summary/。论文的 build_assets.py 从记录的源文件生成表格、图、数字宏和双语摘要, 完整输入哈希记入 generated/asset_manifest.json。

三份原始特征矩阵未重复存入 Git。元数据记录精确文件哈希、检查点哈希、形状、预处理、提取代码版本和运行环境。重新提取需要原始公开数据及模型权重, 不假设不同硬件逐位一致。仓库保留 manifest 和足够的结果表, 可在没有这些矩阵时复现报告的汇总结果。

C 补充结果

PACS/Office-Home、 $K = 3$ 时, A-opt 平均 Brier 为 0.826769, DPP 为 0.829162, MMD 为 0.828719。A-opt 减去基线的配对区间分别为 $[-0.007449, 0.000731]$ 和 $[-0.003392, -0.000712]$ 。事后审计覆盖每个任务全部 220 个组合。Oracle 相对 DPP 的改善空间描述性 95% 区间为 $[0.162, 1.617]\%$; 仅 PACS photo 在目标单位层面超过原 2% 门槛。相对父方法的事后测试最优包络, oracle 平均还能改善 0.087%。该包络是基于结果的参照, 不是可用于选择的基线。

表 4 给出主规模下完整的 Brier 召回比较。A-opt 和 MMD 平均相对选择遗憾相同: 岭回归为 0.001006%, 逻辑回归为 0.103%。两者全部新种子主设置 Brier 短名单均包含经验 oracle。

A-opt 最低分类错误率召回出现在 DINOv2、Quickdraw、逻辑回归、投影种子 20260918 的任务中。测试错误率 oracle 为 85.9863%, 验证选择为 87.6465%。虽然前十名召回只有 40%, 短名单仍保留 oracle。因此, 保留最佳成员与保留前十名回答不同问题, 二者也都不同于可用模型的绝对质量。

四编码器、十个构造种子的谱扫描使用六个重叠设置和四种预算, 每个草图秩有 960 个配置。秩为 10, 20, 50 时, 相对仅使用秩的对照, Gram 草图在精确合并有效秩上的收益分别为 2.09, 3.81, 4.94%, DPP 为 4.90, 5.48, 5.68%。这些是几何目标收益, 不是分类准确率。熵连续性界采用 Audenaert (2007) 这一类型的界; 2,880 个已选择前缀区间全部覆盖, 但 7,200 个

表 3: 探索性 DomainNet 补实验评价大小为 $s = 227$ 的短名单。测试前十名召回率 (%) 先在每个目标域内平均两个编码器和四个新投影种子, 再对六个域平均。Ridge 指 ridge-softmax; NLL 和错误率分别使用对应验证损失作最终选择。

Readout	Metric	A-opt	MMD	Random
Ridge	Brier	98.33	99.38	50.12
Ridge	NLL	98.54	99.38	49.86
Ridge	Error	96.25	97.50	48.63
Logistic	Brier	98.33	98.96	48.97
Logistic	NLL	98.54	99.79	48.61
Logistic	Error	97.29	97.92	49.04

表 4: 表中报告全部补实验评分规则在 $s = 227$ 时的 Brier 前十名召回率 (%)。平均方式与表 3 相同, 不包括原种子对照。

Screen	Ridge	Logistic
Target A-opt	98.33	98.33
Second-moment MMD	99.38	98.96
Bayesian D-opt	82.29	86.46
Merged effective rank	80.42	85.42
Random (20 repeats)	50.12	48.97
Target energy	41.04	33.96
DPP subspace	28.75	35.42
Domain balance	26.46	31.67

评价的贪心步骤没有一步得到认证。结果来源为 `results/two_stage_controlled_rank_sweep_corrected_v3/`。这并不意味着所有低秩草图都必然失败。

独立 E5 研究将草图载荷与紧凑对称 float64 Gram 比较, 而非与更大的稠密存储比较。在覆盖完整网格、平均字节比不超过 25% 的策略中, 与 Full-Gram 贪心的最佳所选集合一致率为 15.42%, 由自适应秩上限 2 获得, 平均字节比为 14.91%。其成对证书率为 3.91%, 完整选择认证率为零。自适应回退能够实现完全所选集合一致, 但计入此前传输后, 平均成本约为紧凑 Gram 字节的 160%, 未达到决策与通信的联合要求。参照是 Full-Gram 贪心, 而非穷举全局最小解。

另一项早期实验在 21 个来源上训练源监督 bottleneck adapter, 使用四个编码器、五个 adapter 种子审计七个目标。目标训练内验证采用三个分层五折划分, 选择冻结后独立读取 held-out 目标测试集。冻结 identity 平均准确率为 0.83654, 未训练随机 adapter 为 0.77144, 验证 oracle 源监督 adapter 为 0.76951。后者比 identity 低 0.06703, 目标聚类 95% 区间为 $[-0.09771, -0.04400]$ 。相对该 adapter 族的小短名单遗憾因而不代表下游收益。这不是 DomainNet 实验, 也不是对所有适应方法的否定。结果位于 `results/two_stage_repeated_cv_utility_corrected_v3/`。

C.1 决策预算重分析

事后预算审计使用四个新投影种子和两种读出器, 不挑选有利种子。对每个任务和终点, 穷举验证仅按验证损失选择组合, 再将其测试损失作为已冻结短名单选择的配对参照。经验测试 oracle 仍是用于审计的下界参照, 与该可部署参照不同。保留全部五个原始预算。

绝对差敏感性网格为: Brier 的 0.001, 0.005, 0.01, NLL 的 0.01, 0.05, 0.1, 错误率的 0.5, 1, 2 个百分点。超差指示量在平均随机重复之前计算; 对平均损失再应用阈值会回答不同问题。描述性配对 bootstrap 对六个域均值进行 2,000 次重采样, 不涵盖共享源池引起的依赖、验证重采样或独立数据集。全部终点曲线、配对域差和阈值比例见 `results/target_conditioned/revision_20260922/budget_audit/`。脚本 `scripts/analyze_e2b_decision_budget.py` 核验已记录损失的哈希, 并从验证文件构造穷举参照。

表 5: 表中报告逻辑回归的最终 Brier 及超过穷举验证参照 0.005 的比例。先平均随机重复, 再在域内平均编码器和种子, 最后对六域平均。容忍值属于探索性分析, 不是新成功门槛。

Screen	Fits	Test Brier	Gap > 0.005 (%)
Random	227	0.866030	15.52
Target A-opt	50	0.864511	2.08
MMD	50	0.864365	2.08
Exhaustive validation	455	0.864118	0.00




图 3: 两个面板报告不同候选族的事后诊断。左图展示各 PACS/Office-Home 目标内平均编码器后, oracle 相对 DPP 的 Brier 改善空间。右图展示原 DomainNet 任务的相对 Brier 最好到最坏跨度。原评价门槛保持不变。

C.2 损失分辨能力与测试样本稳定性

附录图 3 的事后损失跨度诊断为理解原遗憾判据提供了参照。所有候选的相对 Brier 遗憾都低于 5%, 因此该门槛无法在本实验中区分筛选是否成功。召回率提供了更有信息量的比较, 但也引出另一个问题: 测试前十名对测试样本的抽取有多敏感?

CUDA 重建首先复现了原实验的全部 Brier 前十名集合。随后固定拟合模型和验证选择, 对测试样本进行配对 bootstrap。重采样与原前十名集合平均仅重叠 85.15%, 但 A-opt 和 MMD 仍分别保留重采样前十名的 97.42% 和 97.85%。在这些测试样本变化下, 较宽短名单比精确排名成员更稳定。

改变指标对“哪些组合算好”的影响更大: 原实验 Brier 与分类错误率前十名平均仅重叠 29.17%。因此, 即使预筛选在若干指标上都有较高平均召回, 仍应按预期部署指标评价。重采样协议与其他指标比较见附录 B。

C.3 候选构造与域级对照

固定挑战使用投影种子 20260917、两种编码器和两种读出器。每域原有 1536 张源图像按照固定种子、域标识与样本标识拼接后的 SHA-256 排序, 再分成三个 512 样本块。成员确定不使用标签、特征值或结果; 目标选择集、验证集和测试集保持不变。原构造同时重跑作为控制: 65520 个验证与测试损失值均与此前对应种子的记录完全一致。重分块不再使用 CLIP 分层标签, 但仍以原来选出的源图像集合为条件; 它不是独立数据集, 也没有新增测试样本。

均值匹配最小化 $\|\bar{h}_S - \bar{h}_T\|_2^2$, 即线性核 MMD 评分。域级匹配额外使用源域标识, 以整个源域的矩替代各块的矩, 按候选的域样本比例加权, 再最小化与目标矩的 Frobenius 距离平方。原挑战按字典序打破平局。由于域级匹配产生大量结构性平局, 额外的事后审计使用 20 个

固定种子，在每个同域组成组内随机排列。它在读取测试损失前冻结全部新验证选择，不重新拟合或改变分类器参数。发布的曲线仍保留原平局协议结果。

表 6: 构造挑战使用逻辑回归 Brier。最终损失由规模 $s = 50$ 的名单内验证选择得到。后两列是每个非单例同域组成组保留一半候选时，对一个经验最优候选的保留率，不是最终选择准确率。先在目标内平均组成组与编码器，再平均六个目标。域级匹配的最终损失使用 20 次随机平局处理；其组内项为均匀平局的精确期望。

Screen	Final Brier ($s = 50$)		Within-composition (%)	
	Original	Hash	Original	Hash
Target A-opt	0.863170	0.869699	77.22	55.83
MMD	0.863110	0.869257	76.11	55.00
Mean matching	0.863713	0.873038	75.28	57.78
Domain moment (random ties)	0.863667	0.869356	45.68	45.68
Random	0.870013	0.874244	45.04	45.31

每个目标有 20 个含九候选的组成组和十个含 27 候选的组成组，排除五个单候选组。组内候选具有完全相同的域重数与总样本数。先平均随机重复，再平均组成组、编码器与目标域。域级评分在组内恒定，因此均匀平局下的最优候选保留期望为 $(20 \cdot 4/9 + 10 \cdot 13/27)/30 = 45.68\%$ 。字典序的组内结果仍有记录，但不解释为域级方法的区分能力。

哈希重分块后，A-opt 与 MMD 对逻辑回归分类错误率最优候选的保留率分别为 41.94%、35.28%，随机选择为 45.75%。两者的平均 Brier 遗漏仍低于随机，但优势小于原分块。这些依赖指标的观察描述条件性排序表现，既不构成人群保证，也未从特定分块的其他属性中分离出异质性的因果贡献。

完整曲线和同域组成审计见 `results/target_conditioned/revision_20260922/challenge_summary/`，域级随机平局结果见 `results/target_conditioned/revision_20260922/domain_tie_audit/`。原始三阶段记录通过哈希绑定候选成员、源特征、配置、上游选择与数值文件。本地汇总核验全部数值哈希与上游签名；服务器在访问测试数据前已检查冻结模型哈希。

C.4 配对质量与计算成本

计时研究使用原候选构造与投影种子 20260917。每个编码器-目标-读出任务独立执行 A-opt、MMD、随机筛选与穷举验证，重复三次，并用固定种子确定方法顺序。BLAS 使用单线程。各短名单检查点测量一次排序后的累计时间，不跨方法复用拟合模型。岭回归按需缓存已使用块的 float64 Gram 与标签右端项，穷举也使用这一实现。首版 float32 Gram 的岭回归时间保留在归档中，但不进入任何表格。

每次计时的验证损失与选择均与冻结科学审计核对。图 4 的质量来自同样三次运行实际选中的模型，Brier、NLL 与错误率分别使用对应验证指标。因此，这里的随机质量坐标平均三次计时排名，而不是主科学审计中的 20 次排名。先在任务内平均重复，再在目标内平均编码器，最后六目标等权平均；时间中位数作为诊断保留。

内存计时不包括阶段包加载、完整性校验和缓存特征投影。表 7 为两个各含六目标的编码器批次单独核算这些操作。目标感知方法加载选择包与验证包，随机和穷举只需要验证包。共享准备成本在每个编码器批次内只计一次，不折算成虚构的单任务时间。

表 7: 磁盘缓存批次成本以秒计，包括输入加载、完整性检查、投影和全部十二个编码器-目标决策。这里是两个六目标批次的总时间，而表 1 是单任务均值；选择及损失不变。

Readout	A-opt (50)	MMD (50)	Random (227)	Full (455)
Ridge	9.35	5.46	10.40	19.18
Logistic	56.77	54.63	255.89	515.12

原始图像测量包括模型初始化、图像读取与哈希检查、解码、预处理、推理、CPU 特征传输，以及归一化和投影。各源块独立计时；随机筛选只收取实际前缀中块并集的成本，几何评分与穷举验证则使用全部 15 个可用源块。所有方法还需要目标验证特征，仅目标感知评分需




图 4: 最终测试 Brier 分别相对于配对决策时间和图像成本分项核算作图。每条曲线包括预算 10, 25, 50, 100, 227, 叉号为 455 候选的穷举验证。两行纵轴尺度不同。均值使用两编码器、六目标, 以及每方法三次独立执行。原始图像成本不包括候选构造、下载、缓存写盘和测试审计。

要目标选择样本。不处理测试图像。测量以固定候选池清单为输入, 因此不含基于 CLIP 的候选构造。

服务器采用 Intel Xeon Platinum 8352V CPU 和 NVIDIA vGPU-32GB。特征提取使用 CUDA 12.4、PyTorch 2.5.1、不启用 TF32 的 float32 推理、批大小 64, 以及四个数据加载进程。读出环境为 NumPy 1.26.4、SciPy 1.16.1 和 scikit-learn 1.7.1。特征分项只测量一遍, 不清空操作系统磁盘缓存, 并计入块级加载进程启动成本。因此, 加总结果描述的是这一实现和复用情形, 不是与硬件无关的加速比。

全部 32 条质量时间曲线记录、三种损失终点、配对差异和 384 条任务级预算记录见 [results/target_conditioned/revision_20260922/cost_summary/](#), 并附有独立计时记录及逐块特征测量。论文核验脚本从这些记录独立重算配对质量坐标、随机块并集和全部加法总成本。