

Collapse Model : 精确理论、近似边界与最终定位

目录

Collapse Model : 精确理论、近似边界与最终定位	2
1. 研究问题	2
2. 完全一般的精确起点	2
2.1 一般问题的真正困难	3
2.2 该基底表达的逐步推导	4
2.3 对称的完整基表达	5
2.4 稠密 C 为什么阻止逐方向分解	6
2.5 与 principal angles 的关系	6
3. 为什么 principal angles 本身不够	6
4. 成对、解耦方向下的精确局部模型	7
4.1 逐方向能量比例	8
4.2 精确的逐方向有效秩	9
5. 比例谱与统一 alignment 的闭式模型	9
6. 当前闭式预测器的正确身份	10
7. 现有理论的主要缺陷	11
7.1 全局核范数比不是逐方向比例	11
7.2 平均 alignment 不是充分统计量	11
7.3 alignment 与谱权重存在耦合	11
7.4 四个标量不是充分统计量	12
7.5 原误差界缺失必要控制量	12
8. 不同塌陷情景的精确解释	12
8.1 完全方向塌陷	12
8.2 完全方向互补	13
8.3 能量塌陷	13
8.4 平衡且互补	13
8.5 平衡但高度重合	14
8.6 非均匀混合塌陷	14
8.7 交叉耦合塌陷	14
9. 可以进一步发展的精确与近似理论	14

9.1 从标量摘要升级为分桶摘要	14
9.2 基于扰动理论的新误差路线	15
9.3 从绝对误差保证转向排序保证	15
9.4 从普适证书转向可诊断的置信度	15
10. 与数据池压缩应用的关系	16
11. 论文最终应保留与撤回的内容	16
12. 最终理论定位	17
12.1 一句话版本	17
12.2 更完整的论文定位	17
12.3 这一定位为何仍有价值	17
13. 后续理论工作的优先级	18

Collapse Model：精确理论、近似边界与最终定位

1. 研究问题

给定两个由同一冻结编码器得到的特征矩阵

$$H_A \in \mathbb{R}^{n_A \times d}, \quad H_B \in \mathbb{R}^{n_B \times d},$$

将它们按样本维纵向合并：

$$H_{A \cup B} = \begin{bmatrix} H_A \\ H_B \end{bmatrix}.$$

Collapse Model 试图回答三个递进问题：

1. 合并矩阵的奇异值谱如何由两个输入矩阵决定？
2. 哪些谱能量与子空间几何因素导致合并后的多样性增加或塌陷？
3. 能否仅用少量数据集级摘要，近似预测合并有效秩并进行数据池选择？

这三个问题对应不同的理论难度。第一个问题存在一般精确表达；第二个问题在方向可配对时存在精确的局部分解；第三个问题通常只能得到近似预测器，而不是普适闭式定理。

2. 完全一般的精确起点

记

$$H_A = U_A \Sigma_A V_A^\top, \quad H_B = U_B \Sigma_B V_B^\top.$$

合并矩阵的右 Gram 矩阵满足无条件精确恒等式：

$$G_{A \cup B} = H_{A \cup B}^\top H_{A \cup B} = H_A^\top H_A + H_B^\top H_B.$$

代入 SVD 得到：

$$G_{A \cup B} = V_A \Sigma_A^2 V_A^\top + V_B \Sigma_B^2 V_B^\top.$$

若 $\lambda_j(G_{A \cup B})$ 是该矩阵的特征值，则合并矩阵的奇异值为

$$s_j = \sqrt{\lambda_j(G_{A \cup B})}.$$

采用奇异值归一化的谱熵有效秩时，定义

$$p_j = \frac{s_j}{\sum_\ell s_\ell}, \quad r_{\text{eff}}(H_{A \cup B}) = \exp \left(- \sum_j p_j \log p_j \right).$$

因此，一般情况下的精确答案是：先计算两个加权子空间算子之和的完整谱，再计算谱熵。这个答案没有理论漏洞，但仍依赖完整矩阵或足以恢复完整 Gram 算子的高维信息，不能直接满足 summary-only selection 的目标。

2.1 一般问题的真正困难

困难不在于不知道两个输入矩阵各自的谱，而在于不知道它们的谱权重如何与相对方向对应。将 V_A 的右奇异向量补全为整个特征空间的一组正交基 Q_A ，并把 Σ_A^2 用零特征值补成 $d \times d$ 的对角矩阵。令

$$C = Q_A^\top V_B.$$

则在 Q_A 基底，核心算子精确写为

$$Q_A^\top G_{A \cup B} Q_A = \tilde{\Sigma}_A^2 + C \Sigma_B^2 C^\top,$$

一般的 C 是稠密矩阵。这意味着 A 的一个奇异方向可能同时与 B 的多个方向耦合。仅知道两个子空间的平均 principal-angle alignment，无法恢复这种权重与方向的对应关系。

2.2 该基底表达的逐步推导

为避免低秩矩阵带来的维度歧义，先写两个矩阵的紧致 SVD：

$$H_A = U_A \Sigma_A V_A^\top, \quad V_A \in \mathbb{R}^{d \times \rho_A},$$

$$H_B = U_B \Sigma_B V_B^\top, \quad V_B \in \mathbb{R}^{d \times \rho_B},$$

其中 ρ_A, ρ_B 表示代数秩；后文的 r_A, r_B 专门表示谱熵有效秩。对应 Gram 算子为

$$G_A = V_A \Sigma_A^2 V_A^\top, \quad G_B = V_B \Sigma_B^2 V_B^\top.$$

将 V_A 补全为一个 $d \times d$ 正交矩阵：

$$Q_A = [V_A \ V_{A,\perp}], \quad Q_A^\top Q_A = I_d.$$

由于 Q_A 的前 ρ_A 列就是 V_A ，所以

$$Q_A^\top V_A = \begin{bmatrix} I_{\rho_A} \\ 0 \end{bmatrix}.$$

因此

$$Q_A^\top G_A Q_A = Q_A^\top V_A \Sigma_A^2 V_A^\top Q_A = \tilde{\Sigma}_A^2,$$

其中

$$\tilde{\Sigma}_A^2 = \text{diag}(\sigma_{A,1}^2, \dots, \sigma_{A,\rho_A}^2, 0, \dots, 0) \in \mathbb{R}^{d \times d}.$$

再定义 B 的右奇异方向在 Q_A 基底中的坐标：

$$C = Q_A^\top V_B \in \mathbb{R}^{d \times \rho_B}.$$

于是

$$Q_A^\top G_B Q_A = Q_A^\top V_B \Sigma_B^2 V_B^\top Q_A = C \Sigma_B^2 C^\top.$$

两式相加就得到

$$Q_A^\top G_{A \cup B} Q_A = \tilde{\Sigma}_A^2 + C \Sigma_B^2 C^\top.$$

这是精确等式，不是近似。因为 Q_A 是正交矩阵，左右乘 $Q_A^\top$ 和 Q_A 只是对同一线性算子进行正交换基。因此

$$G_{A \cup B} \quad \text{与} \quad \tilde{\Sigma}_A^2 + C \Sigma_B^2 C^\top$$

具有完全相同的特征值，也就产生完全相同的合并奇异值和有效秩。

此外，由于 V_B 的列正交， C 的列也正交：

$$C^\top C = V_B^\top Q_A Q_A^\top V_B = I_{\rho_B}.$$

所以 C 不是任意系数矩阵，而是 B 的正交右奇异方向在 A 的完整正交坐标系中的表示。

2.3 对称的完整基表达

也可以把 V_B 补全为完整正交基 Q_B ，并定义

$$R = Q_A^\top Q_B.$$

此时 $R \in \mathbb{R}^{d \times d}$ 是正交矩阵，满足

$$R^\top R = R R^\top = I_d.$$

令 $\tilde{\Sigma}_B^2$ 为补零后的 $d \times d$ 对角谱矩阵，则

$$Q_A^\top G_{A \cup B} Q_A = \tilde{\Sigma}_A^2 + R \tilde{\Sigma}_B^2 R^\top.$$

这个表达把一般合并问题拆成三类信息：

1. $\tilde{\Sigma}_A^2$ ：数据集 A 在各方向上的谱能量；
2. $\tilde{\Sigma}_B^2$ ：数据集 B 在各方向上的谱能量；
3. R ：两套完整右奇异坐标系之间的相对旋转。

因此，合并谱不仅取决于“两侧各有多少能量”，还取决于 B 的每个谱权重经 R 旋转后落到 A 的哪些方向上。

2.4 稠密 C 为什么阻止逐方向分解

展开 B 项的矩阵元素：

$$(C\Sigma_B^2 C^\top)_{ij} = \sum_{k=1}^{\rho_B} \sigma_{B,k}^2 C_{ik} C_{jk}.$$

当 $i \neq j$ 时，只要存在某个 B 方向同时在 Q_A 的第 i 和第 j 个方向上有非零投影，就会产生非零交叉项。这些交叉项把不同的 A 方向耦合起来，使整个特征值问题不能拆成独立标量或独立方向对。

只有当经过适当的方向排列后， R 或 C 具有相互独立的稀疏配对结构时，算子才会分解成若干互不耦合的低维 blocks。最理想的情形是每个 A 方向只与一个 B 方向耦合，此时每个联合子空间至多为二维，进而得到后文的 2×2 特征值公式。

2.5 与 principal angles 的关系

紧致交叉矩阵

$$M = V_A^\top V_B$$

是 C 的前 ρ_A 行。 M 的奇异值是两个右奇异子空间之间 principal angles 的余弦：

$$\sigma_i(M) = \cos \theta_i.$$

但是，principal angles 只保留 M 的奇异值，不保留 M 的左右奇异向量。这些奇异向量决定了 principal directions 如何由原始谱方向混合而成。若 Σ_A^2 和 Σ_B^2 不是各向同性的，这种混合会改变大谱权重与高 alignment 的配对方式，从而改变合并谱。

所以：

M 的完整结构包含谱方向之间的对应关系；principal-angle 集合只包含子空间几何的旋转不变量；平均 α 又进一步把整个角度集合压缩成一个标量。

信息在这两次压缩中逐步丢失。这正是一般情形无法仅由平均 alignment 精确预测合并有效秩的根本原因。

3. 为什么 principal angles 本身不够

Principal angles 描述两个子空间整体的相对位置，但它们不自动满足以下条件：

- principal vectors 同时也是 H_A 和 H_B 的奇异向量；
- 第 i 个大奇异值方向恰好与第 i 个 principal direction 对应；

- 不同方向对之间不存在交叉耦合；
- 相同 alignment 出现在谱头部与谱尾部时具有相同影响。

这一区分十分关键。两个矩阵可以具有：

- 相同的个体奇异值集合；
- 相同的子空间维数；
- 相同的 principal-angle 集合；

但如果奇异值在 principal-vector bases 上的排列不同，合并谱仍然可能不同。

因此，原理论中需要明确加入一个比“存在 principal angles”更强的兼容性条件：奇异向量基与成对 principal-vector bases 兼容。

4. 成对、解耦方向下的精确局部模型

假设存在方向对

$$v_{A,i}, \quad v_{B,i},$$

满足

$$v_{A,i}^\top v_{B,j} = 0, \quad i \neq j,$$

以及

$$v_{A,i}^\top v_{B,i} = \cos \theta_i.$$

令

$$\alpha_i = \cos^2 \theta_i.$$

此时不同方向对相互解耦，第 i 对方向对应一个精确二维谱问题。其两个 Gram 特征值为

$$\lambda_{\pm,i} = \frac{\sigma_{A,i}^2 + \sigma_{B,i}^2 \pm \sqrt{(\sigma_{A,i}^2 - \sigma_{B,i}^2)^2 + 4\sigma_{A,i}^2 \sigma_{B,i}^2 \alpha_i}}{2}.$$

合并矩阵对应的两个奇异值为

$$s_{+,i} = \sqrt{\lambda_{+,i}}, \quad s_{-,i} = \sqrt{\lambda_{-,i}}.$$

如果所有方向均满足该解耦结构，完整合并谱就是

$$\{s_{+,1}, s_{-,1}, s_{+,2}, s_{-,2}, \dots\}.$$

这应当成为 Collapse Model 修订后最重要的精确理论结果。

4.1 逐方向能量比例

定义

$$\gamma_i = \frac{\sigma_{B,i}}{\sigma_{A,i}}.$$

则

$$\lambda_{\pm,i} = \sigma_{A,i}^2 \frac{1 + \gamma_i^2 \pm \sqrt{(1 - \gamma_i^2)^2 + 4\gamma_i^2 \alpha_i}}{2}.$$

定义分支缩放因子

$$c_{\pm,i} = \sqrt{\frac{1 + \gamma_i^2 \pm \sqrt{(1 - \gamma_i^2)^2 + 4\gamma_i^2 \alpha_i}}{2}},$$

则

$$s_{\pm,i} = \sigma_{A,i} c_{\pm,i}.$$

对应的局部分支权重为

$$q_i = \frac{c_{+,i}}{c_{+,i} + c_{-,i}}.$$

一般情况下，每个方向都有自己的 γ_i 、 α_i 与 q_i 。因此，真正精确的模型通常不存在一个对所有方向通用的单一 r^* 。

4.2 精确的逐方向有效秩

令总核质量为

$$Z = \sum_j \sigma_{A,j}(c_{+,j} + c_{-,j}).$$

则合并谱的归一化权重为

$$p_{\pm,i} = \frac{\sigma_{A,i} c_{\pm,i}}{Z}.$$

所以

$$r_{\text{eff}}(H_{A \cup B}) = \exp \left[- \sum_i (p_{+,i} \log p_{+,i} + p_{-,i} \log p_{-,i}) \right].$$

这个表达在成对、解耦条件下是精确的，但它需要完整的逐方向信息，因而属于解释性理论，而不是通信成本很低的选择算法。

5. 比例谱与统一 alignment 的闭式模型

若进一步假设

$$\sigma_{B,i} = \gamma \sigma_{A,i}, \quad \forall i,$$

以及

$$\alpha_i = \alpha, \quad \forall i,$$

则

$$c_{\pm,i} = c_{\pm}, \quad q_i = q.$$

整个合并谱变为同一基础谱的两个缩放副本：

$$\{c_{+} \sigma_{A,i}\}_i \cup \{c_{-} \sigma_{A,i}\}_i.$$

其中

$$q = \frac{c_+}{c_+ + c_-}.$$

此时谱熵具有精确分解：

$$\mathcal{H}_{\text{merged}} = \mathcal{H}_A + H_b(q),$$

因而

$$r_{\text{merged}} = r_A \exp(H_b(q)).$$

这里

$$H_b(q) = -q \log q - (1 - q) \log(1 - q).$$

由于 proportional spectra 意味着两个归一化奇异值谱相同，所以必然有

$$r_A = r_B.$$

因此，允许 $r_A \neq r_B$ 的当前预测公式不能作为比例谱模型的精确推论。

6. 当前闭式预测器的正确身份

当前实用预测器可写成

$$\log \hat{r}_{\text{merged}} = H_b(q) + q \log r_{\text{dom}} + (1 - q) \log r_{\text{sub}}.$$

它可以理解为：

- 用 $H_b(q)$ 表示两个合并谱分支的混合熵；
- 用 q 和 $1 - q$ 对两个输入谱熵进行几何插值；
- 用全局 γ 和平均 α 近似所有逐方向的 γ_i 和 α_i 。

这一公式具有明确的理论动机，但在一般谱上不是精确恒等式。它更准确的定位是：

由精确双分支 Gram 谱结构启发的低维摘要近似。

这种定位介于纯经验回归与普适定理之间。模型形式来自精确谱分析，但其一般化效果必须依靠真实数据实验、校准和依赖性稳健统计来验证。

7. 现有理论的主要缺陷

7.1 全局核范数比不是逐方向比例

论文定义

$$\gamma = \frac{\sum_i \sigma_{B,i}}{\sum_i \sigma_{A,i}}.$$

它只约束奇异值之和，不能推出

$$\sigma_{B,i} = \gamma \sigma_{A,i}.$$

因此，把全局 γ 直接代入每个局部 block，是一个近似步骤，而不是代数恒等变换。

7.2 平均 alignment 不是充分统计量

例如

$$(\alpha_1, \alpha_2) = (1, 0)$$

与

$$(\alpha_1, \alpha_2) = (0.5, 0.5)$$

具有相同均值，但一般会产生不同的分支谱。平均 alignment 丢失了方向间异质性。

7.3 alignment 与谱权重存在耦合

头部奇异方向上的高 alignment 通常比谱尾部的高 alignment 影响更大。因此，一个更合理的摘要应考虑谱加权 alignment，例如

$$\bar{\alpha}_w = \frac{\sum_i w_i \alpha_i}{\sum_i w_i},$$

其中 w_i 可以依赖 $\sigma_{A,i} \sigma_{B,i}$ 或该方向对的核质量。

7.4 四个标量不是充分统计量

一般情况下， r_A 、 r_B 、全局 γ 和平均 α 不能唯一确定合并有效秩。它们没有保留：

- 两侧完整谱形状；
- γ_i 的分布；
- α_i 的分布；
- alignment 与谱权重的相关性；
- 非配对方向的交叉耦合。

因此，不存在一个仅依赖这四个标量、对所有矩阵均精确的普适预测公式。

7.5 原误差界缺失必要控制量

合理的误差界至少需要控制：

- γ_i 围绕全局 γ 的离散程度；
- α_i 的谱加权方差；
- 两个归一化谱之间的距离；
- 非配对耦合矩阵的范数；
- 谱尾部对熵的敏感性。

原 Theorem 1 未控制这些因素，因而可能在上界右侧为零时仍产生非零误差。当前形式应撤回，而不是仅修改证明文字。

8. 不同塌陷情景的精确解释

8.1 完全方向塌陷

若

$$\alpha_i = 1,$$

则

$$\lambda_{+,i} = \sigma_{A,i}^2 + \sigma_{B,i}^2, \quad \lambda_{-,i} = 0.$$

两个输入方向完全合并，只剩一个非零分支。这是严格意义上的 directional collapse。

8.2 完全方向互补

若

$$\alpha_i = 0,$$

则

$$\lambda_{+,i} = \max(\sigma_{A,i}^2, \sigma_{B,i}^2),$$

$$\lambda_{-,i} = \min(\sigma_{A,i}^2, \sigma_{B,i}^2).$$

两个方向均被保留。若能量也较平衡，谱熵通常显著增加。

8.3 能量塌陷

若

$$\gamma_i \rightarrow 0,$$

则

$$\lambda_{+,i} \rightarrow \sigma_{A,i}^2, \quad \lambda_{-,i} \rightarrow 0.$$

即使两个方向正交，弱侧也难以在归一化谱中形成有影响力的分支。 $\gamma_i \rightarrow \infty$ 时同理，只是由 B 主导。

8.4 平衡且互补

若

$$\gamma_i \approx 1, \quad \alpha_i \approx 0,$$

则两个分支接近等权，每个方向对近似产生两个独立谱方向。该区域通常具有最大的谱熵增益。

8.5 平衡但高度重合

若

$$\gamma_i \approx 1, \quad \alpha_i \approx 1,$$

则一个分支吸收几乎全部能量，另一个分支接近零。能量增加但独立方向不增加。这是 clone attack 所暴露的典型情景。

8.6 非均匀混合塌陷

真实数据最可能同时包含：

- 头部方向的 directional collapse；
- 尾部方向的互补增益；
- 部分方向的 energy collapse；
- 部分方向的近似平衡。

因此，完整数据集对不一定属于唯一 regime。更精确的表述是：不同方向对处于不同状态，整体有效秩是这些局部状态经过谱权重归一化后的综合结果。

8.7 交叉耦合塌陷

当 $C = V_A^\top V_B$ 稠密时，一个强方向可能把能量分散到多个对侧方向。此时逐方向 2×2 解释也只是近似。可以将 C 分为近似配对部分与残差：

$$C = C_{\text{pair}} + E.$$

E 的谱范数或 Frobenius 范数可作为非配对耦合强度，并可能成为未来误差界的重要控制量。

9. 可以进一步发展的精确与近似理论

9.1 从标量摘要升级为分桶摘要

不必在“完整谱”与“四个标量”之间二选一。可以按谱质量把方向划分为若干桶，每个桶传输：

- 核质量；
- 局部有效秩；
- 加权平均 γ_i ；
- 加权平均与方差 α_i ；

- 跨桶耦合摘要。

这会形成多分辨率 Collapse Model：通信量仍远低于完整特征，但比单一 γ 和 α 更忠实。

9.2 基于扰动理论的新误差路线

可以定义一个理想的 paired block 算子 G_0 和真实算子 G ：

$$G = G_0 + \Delta G.$$

先用 Weyl、Hoffman--Wielandt 或相关矩阵扰动工具控制特征值变化，再把奇异值变化传递到归一化谱，最后使用带有最小质量或截断条件的熵连续性界。

一个可能的新的误差结构是

$$|\log r_{\text{eff}}(G) - \log \hat{r}| \leq C_1 \|E\| + C_2 \text{Var}_w(\gamma_i) + C_3 \text{Var}_w(\alpha_i) + C_4 D_{\text{spec}}(A, B) + \varepsilon_{\text{tail}}.$$

这里的常数必须依赖谱间隙、截断阈值或最小归一化谱质量。该形式目前只是研究方向，不能在完整证明时写成定理。

9.3 从绝对误差保证转向排序保证

数据池选择真正需要的往往不是精确预测 r_{merged} ，而是正确比较两个候选数据集的边际增益。因此可以研究：

$$\Pr(\widehat{\Delta}(A, B_1) > \widehat{\Delta}(A, B_2) \Rightarrow \Delta(A, B_1) > \Delta(A, B_2)).$$

如果两个候选的真实增益间隔大于近似误差之和，就可以得到局部排序稳定性。相比普适的有效秩绝对误差界，这种结果更贴近 greedy selection 的实际用途，也更可能在合理假设下成立。

9.4 从普适证书转向可诊断的置信度

可以用以下信号判断摘要近似何时可信：

- γ_i 的离散程度较小；
- α_i 的加权方差较小；
- 非配对残差 $\|E\|$ 较小；
- 两侧谱形状距离较小；
- 预测候选之间的 margin 足够大。

当这些量较差时，系统不必继续给出强预测，而可以回退到：

- 传输更多谱分桶摘要；

- 请求低秩 sketch；
- 对少量候选执行真实合并计算；
- 将结果标记为低置信度。

这种“预测器加失效诊断”比宣称一个实际上不成立的普适证书更可靠。

10. 与数据池压缩应用的关系

Collapse Model 的直接用途不是替代端到端训练，而是在训练前进行数据集级预筛选。典型流程是：

候选数据源

- 冻结编码器特征
- 谱与子空间摘要
- 估计边际表示覆盖
- 排除高度冗余的数据源
- 对缩小后的候选池进行真实训练或适配

适用场景包括：

- 只能从 M 个数据源中采购或保留 $k \ll M$ 个；
- 原始数据或完整特征不便跨机构共享；
- 数据以流式方式持续到达；
- 存储、授权或适配预算有限；
- 穷举所有数据集组合并实际训练成本过高。

它回答的是：

哪些数据源在冻结表示空间中提供互补覆盖，哪些数据源主要重复已有方向？

它不能单独回答：

哪个数据组合一定取得最高的端到端下游准确率？

因此，Collapse 应当被视为低成本筛选器和冗余诊断器，而不是训练效果的替代评价器。

11. 论文最终应保留与撤回的内容

内容	最终定位
$G_{A \cup B} = G_A + G_B$	无条件精确恒等式
成对方向的 $\lambda_{\pm, i}$	在 pairing/decoupling 条件下精确

内容	最终定位
energy/directional collapse 机制	局部谱层面成立
proportional-spectrum 闭式分解	在强假设下精确
允许 $r_A \neq r_B$ 的摘要公式	理论启发的经验近似
superadditivity threshold	理想模型下精确，一般数据上是诊断量
原 Theorem 1	当前结论无效，应撤回
自然池上的 alignment 增量	当前证据有限，不应宣称普遍优势
clone attack	alignment 作为冗余保护机制的有力证据
冻结特征压缩	当前主要实证应用
lightweight adapter	初步的数据消费型验证
端到端预训练收益	尚未建立

12. 最终理论定位

12.1 一句话版本

合并特征矩阵的谱由个体谱能量与右奇异子空间几何共同决定；在成对、解耦方向条件下，这种相互作用具有精确的 2×2 Gram 特征值表达，而实用 Collapse 公式是将逐方向能量比例和 alignment 压缩为全局摘要后的经验近似。

12.2 更完整的论文定位

Collapse Model 不应再被定位为“一般谱条件下具有普适误差证书的闭式理论”。更准确的定位是：

1. **解释性理论**：揭示合并谱中能量不平衡与方向重叠的不同作用，并在方向配对条件下给出精确局部分解。
2. **理想化解析模型**：在 proportional spectra 与 uniform alignment 下得到可解释的双分支熵公式。
3. **实用摘要预测器**：在一般谱上用少量标量或 sketch 近似完整逐方向结构，并通过真实数据相关性、校准、cluster bootstrap、LODO 与失效案例进行评估。
4. **应用层筛选方法**：在无法穷举训练或共享完整特征时，预筛选具有较高冻结表示覆盖且几何冗余较低的数据源。

12.3 这一定位为何仍有价值

撤回原误差界会降低理论声明的强度，但不会使工作退化为没有结构的经验指标：

- 预测器不是任意回归式，而是从 Gram 谱相互作用推导出的结构化近似；
- 精确 block 分解给出了 alignment 必须进入合并谱分析的数学理由；
- energy collapse 与 directional collapse 对应不同的可解释失效机制；
- clone attack 表明单体 rank 无法在所有情形下替代相对几何；

- 真实数据相关性与依赖性稳健分析支持该近似具有实际预测价值；
- summary-only 设计仍对应隐私受限、流式和预算受限的数据源筛选需求。

因此，最终最稳健的贡献声明不是“我们证明了一般数据集合并有效秩的普适公式”，而是：

我们给出一个精确的局部谱几何模型，基于该模型构造低通信量的合并有效秩近似，并系统验证它作为冻结表征数据池压缩与冗余诊断工具的适用性和局限性。

13. 后续理论工作的优先级

1. 形式化 pairing/decoupling 条件，并证明逐方向 block 定理。
2. 将 proportional-spectrum 闭式结果改写为独立、无矛盾的命题，并明确 $r_A = r_B$ 。
3. 删除原 Theorem 1，避免在 rebuttal 阶段提出未经证明的新普适界。
4. 构造具有相同 r_A, r_B, γ, α 但不同合并有效秩的反例，证明四标量不是充分统计量。
5. 测量真实数据中的 $\text{Var}_w(\gamma_i)$ 、 $\text{Var}_w(\alpha_i)$ 与非配对残差 $\|E\|$ ，分析它们与预测误差的关系。
6. 研究分桶谱摘要或低秩 sketch，在通信成本与预测精度之间建立可验证的折中。
7. 优先研究选择排序稳定性与低置信度回退机制，而不是再次尝试过强的普适绝对误差界。